Cuando los canales miden distinto: evaluación contrafactual del cambio de canal mediante cambio de medida

Pablo

Versión en español · 24 de octubre de 2026

La versión oficial es la inglesa; esta es una traducción con el mismo contenido.

Resumen

Estimamos qué ocurriría si un grupo de unidades (clientes, pacientes, llamadas) fuese atendido por un canal distinto del que lo atiende hoy, sin un experimento aleatorizado. Planteamos la identificación como un cambio de medida: la media contrafactual es una integral sobre la población donante ponderada por la derivada de Radon–Nikodym, que un clasificador calibrado identifica salvo una constante. El foco es un problema frecuente en datos operativos y poco formalizado: que cada canal registre las covariables a su manera. Una variable registrada solo en un canal rompe el soporte por construcción, y lo delata un clasificador seguro ($p = 1$); descartarla es seguro cuando no predice el resultado dadas las demás covariables. Una variable medida con instrumentos distintos en cada canal es más peligrosa: puede conservar el soporte, y el estimador converge entonces a un valor desplazado que ningún análisis de los datos observados distingue de la verdad. Mostramos además que, sin soporte, el estimador doblemente robusto extrapola implícitamente el modelo de resultado, y adaptamos cotas de sensibilidad para la confusión no observada. Cuando el grupo objetivo es un corte en una puntuación conocida, los pesos se obtienen de la propensión de canal ordinaria con el corte impuesto; estimarla con todas las unidades del canal premium reduce en la simulación la dispersión hasta un 59 % cuando el solapamiento es bueno. Una simulación con predicciones registradas antes de ejecutarla contrasta los resultados principales y encuentra además, en nuestro diseño, que el bootstrap por unidad sobrestima la dispersión cuando los pesos estimados son ruidosos.

1 Introducción

Las organizaciones reparten a sus usuarios entre canales de calidad y coste distintos: un centro de atención especializado frente a uno generalista, un hospital frente a atención primaria, un gestor personal frente a una aplicación. Antes de redistribuir, quieren saber cuánto se pierde al mover a un grupo hacia el canal básico y cuánto se gana al mover a otro hacia el premium. Un experimento aleatorizado lo respondería, pero suele ser caro, lento o inviable; lo disponible son datos observacionales de cada canal.

La pregunta central es siempre la misma: *¿cuál sería el resultado medio del grupo objetivo si lo atendiera el otro canal?* Ese resultado no se observa. Sí se observa el resultado de las unidades que ese otro canal atiende hoy, que son distintas. Reponderarlas para que se parezcan al grupo objetivo es, formalmente, un cambio de medida.

El estimando coincide con la media contrafactual de un efecto sobre los tratados, y los pesos de odds $p/(1-p)$ son conocidos (Hirano et al., 2003). También es conocido estimar

cocientes de densidades con clasificadores (Qin, 1998; Bickel et al., 2009; Sugiyama et al., 2012). No reclamamos esas ideas. Nuestras contribuciones son:

1. **Variables de canal y medición distinta.** Tratamos las covariables que solo se registran en uno de los canales como el caso límite del enfoque por patrón de ausencia (D'Agostino y Rubin, 2000; Blake et al., 2020), en el que el patrón lo determina el propio tratamiento. Entonces falla la positividad en el patrón observado, con una masa sin soporte al menos igual a la fracción del grupo objetivo con dato, y la condición de Blake et al. (2020) para el patrón ausente se cumple, en particular, cuando la variable no predice el resultado dadas las demás (Proposiciones 3 y 4). Lo generalizamos a variables medidas con instrumentos distintos en cada canal (Teorema 4): el soporte puede conservarse, y el estimador converge a un valor desplazado que los datos observados no pueden distinguir de la verdad.

2. **El fallo de soporte leído en el clasificador.** La parte de P sin soporte es P restringida a $\{p = 1\}$. Es la construcción clásica de von Neumann de la descomposición de Lebesgue (Rudin, 1987, teorema 6.10), que la literatura de solapamiento usa de forma informal (D'Amour et al., 2021); lo que aportamos es su lectura en términos del clasificador y sus consecuencias: el estimador ponderado se queda con la parte con soporte, mientras que el doblemente robusto extrapola implícitamente el modelo de resultado (Teorema 3 y Corolario 2).

3. **Pesos con corte conocido.** Cuando el grupo objetivo es un corte en una puntuación conocida, los pesos son la propensión de canal ordinaria con el corte impuesto (Proposición 2), como en la práctica habitual del análisis por subgrupos (Rassen et al., 2012). Lo nuevo es mostrar qué se pierde con el clasificador «grupo objetivo frente a donantes»: estimar la propensión con todas las unidades del canal premium reduce mucho la inversión del signo del recorte que produce el clasificador y, con solapamiento bueno, la dispersión, hasta un 59 % con muestras pequeñas; con solapamiento medio o bajo no la reduce (sección 10.3).

4. **Simulación con predicciones registradas.** El límite de cada estimador se calcula antes de ejecutar la simulación, y las predicciones añadidas después de ver un resultado se registraron antes del escenario que las contrasta. Informamos también de las que fallaron; entre ellas, que el bootstrap por unidad, reestimando los modelos auxiliares, sobrestima la dispersión entre un 35 y un 60 % con pesos ruidosos y queda casi calibrado con los pesos de corte conocido (sección 10.5).

Como resultados auxiliares, damos el sesgo exacto del recorte por tope de los pesos verdaderos con normalización (Proposición 5), que complementa a Ma y Wang (2020), y adaptamos las cotas del modelo de sensibilidad marginal (Tan, 2006; Dorn y Guo, 2023) a este estimando, con una forma multiplicativa exacta para resultados raros y una calibración con el modelo de canal (sección 8). El análisis del recorte con pesos estimados se desarrolla en una nota complementaria.

Usamos el lenguaje de la teoría de la medida (derivadas de Radon–Nikodym) en lugar de cocientes de densidades. No es una aportación, sino la formulación estándar; permite tratar covariables mixtas (continuas, categóricas y con valores ausentes) sin suponer que existen densidades.

Trabajo relacionado. El estimando es la media contrafactual de un efecto sobre los tratados, con los pesos de odds de Hirano et al. (2003) y la teoría doblemente robusta con *cross-fitting* de Chernozhukov et al. (2018). El mismo estimando, los pesos de odds y la misma función

de influencia doblemente robusta aparecen en la literatura sobre generalizar y transportar resultados de ensayos a una población objetivo (Westreich et al., 2017; Dahabreh et al., 2019). Para el solapamiento limitado, Crump et al. (2009) redefinen el estimando sobre la región con buen solapamiento. Ma y Wang (2020) caracterizan el sesgo del recorte por descarte en el estimador ponderado, proponen una corrección y muestran que con pesos de cola pesada el límite puede no ser normal; Ma et al. (2023) extienden la corrección a estimadores doblemente robustos con solapamiento débil. Liu et al. (2023) comparan recorte, truncamiento y pesos de solapamiento para el efecto sobre los tratados. Ma y Namkoong (2025) separan el estimando en una parte con solapamiento y otra sin él, y extrapolan la segunda bajo un supuesto de suavidad.

Heckman et al. (1997) encontraron empíricamente que el emparejamiento elimina gran parte del sesgo cuando el grupo de comparación procede del mismo mercado y responde el mismo cuestionario que los participantes; el Teorema 4 formaliza esa lección como un resultado de indistinguibilidad. Cook et al. (2008) y Steiner et al. (2011) documentan también la importancia de medir las covariables igual y con fiabilidad, y que el error de medición diferencial no se corrige sin información externa es conocido en la literatura de error de medición; Imai and Yamamoto (2010) estudian la identificación no paramétrica y el análisis de sensibilidad con error de medición diferencial del tratamiento. Sobre covariables parcialmente observadas, el enfoque por patrón de ausencia (D'Agostino y Rubin, 2000; Blake et al., 2020) exige que la variable no confunda allí donde falta; nuestras variables de canal son el caso en que el patrón lo fija el tratamiento, y la condición que usamos es un criterio de selección de covariables por el lado del resultado (de Luna et al., 2011; VanderWeele y Shpitser, 2011). En el análisis por subgrupos, Rassen et al. (2012) y Dong et al. (2020) comparan la propensión estimada en toda la cohorte con la estimada en cada subgrupo. Sobre diagnósticos, Westreich et al. (2011) muestran que un AUC alto del modelo de propensión no es necesario ni suficiente para controlar la confusión; nuestra simulación añade que tampoco mide el solapamiento. Para diagnosticar fallos de positividad, véanse Petersen et al. (2012) y D'Amour et al. (2021).

2 Planteamiento

Trabajamos en un espacio de probabilidad $(\Omega,\mathcal{F},\mathbb{P})$. Las covariables son una variable aleatoria $X\colon \Omega \to \mathcal{X}$, con $(\mathcal{X},\mathcal{A})$ un espacio estándar de Borel; esto garantiza distribuciones condicionadas regulares y admite vectores mixtos de variables continuas, categóricas y ausentes.

Símbolo	Significado
$D \in \{0,1\}$	Canal que atiende a la unidad (1 = premium, 0 = básico)
$S \in \{0,1\}$	Pertenencia al grupo objetivo, con $\{S=1\} \subseteq \{D=1\}$
$Y(0), Y(1)$	Resultados potenciales si la atiende el canal básico o el premium
Y	Resultado observado
P	Ley de X en el grupo objetivo: $P(A) = \mathbb{P}(X \in A \mid S=1)$
Q	Ley de X en el canal donante: $Q(A) = \mathbb{P}(X \in A \mid D=0)$

Suponemos $\mathbb{P}(S=1) > 0$ y $\mathbb{P}(D=0) > 0$. Un caso típico es $S = \mathbf{1}\{D=1, s(X) \le c\}$: el grupo objetivo son las unidades del canal premium cuya puntuación $s(X)$ cae por debajo de un umbral, por ejemplo la cola de menor propensión de compra.

Estimando. La media contrafactual del grupo objetivo en el canal básico,

$$\theta = \mathbb{E}\big[Y(0) \mid S = 1\big].$$

La pérdida al desviar el grupo es $L = \mathbb{E}[Y \mid S = 1] - \theta$; su primer término se observa directamente. Cuando las unidades generan varias observaciones, P, Q y θ se toman a nivel de observación (sección 7).

Regresiones. Llamamos m_0 a una versión de $\mathbb{E}[Y \mid X, D = 0]$, es decir, una función $\mathcal{A}$-medible y Q-integrable tal que, para todo $A \in \mathcal{A}$,

$$\mathbb{E}\big[Y\,\mathbf{1}\{X \in A\} \mid D = 0\big] = \int_A m_0 \,\mathrm{d}Q.$$

Existe por el teorema de Radon–Nikodym, aplicado a la medida $A \mapsto \mathbb{E}[Y\mathbf{1}\{X \in A\} \mid D = 0]$, que es absolutamente continua respecto de Q, y es única Q-casi seguro. Con X discreta, $m_0(x)$ es la tasa del perfil x; la definición con conjuntos hace falta porque, con X continua, cada valor concreto tiene probabilidad cero. Análogamente, m_0^S es una versión de $\mathbb{E}[Y(0) \mid X, S = 1]$, única P-casi seguro.

Supuestos.

(A1) *Consistencia.* $Y = Y(0)$ sobre $\{D = 0\}$. Falla si el canal básico cambia al recibir las unidades desviadas, por ejemplo por saturación.

(A2) *Intercambiabilidad condicional en media.* $m_0^S = m_0$ P-casi seguro, donde, por (A1), m_0 es también una versión de $\mathbb{E}[Y(0) \mid X, D = 0]$. Solo concierne al canal básico: entre unidades con el mismo perfil, las del grupo objetivo obtendrían en él, en media, el mismo resultado que las que atiende hoy. No dice nada sobre $Y(1)$ y no es contrastable con los datos.

(A3) *Soporte.* $P \ll Q$: todo conjunto de perfiles con probabilidad cero en el canal donante tiene probabilidad cero en el grupo objetivo.

(A4) *Integrabilidad.* $\mathbb{E}[|Y(0)| \mid S = 1] < \infty$ y $\mathbb{E}[|Y| \mid D = 0] < \infty$; se cumple si Y está acotada.

Observación 1 (A2 presupone A3)**.** Como m_0 solo está determinada Q-casi seguro, la igualdad P-casi seguro de (A2) depende de la versión elegida salvo que $P \ll Q$. Si P tiene masa donde Q no la tiene, m_0 es arbitraria allí y ningún dato del canal donante la fija. Este hecho reaparece en el Teorema 3: la parte del grupo objetivo sin soporte no es estimable, no solo difícil de estimar.

Observación 2 (Descomposición estructural de la pérdida)**.** Si el resultado es una suma de componentes, $Y = \sum_k Y_k$ (por ejemplo, compras de distintos productos), y el canal básico no puede producir las componentes de un conjunto K_{ex}, es decir, $Y_k(0) = 0$ casi seguro para $k \in K_{\text{ex}}$, entonces, con consistencia también en el canal premium ($Y = Y(1)$ sobre $\{D = 1\}$) y por linealidad,

$$L = \sum_{k \in K_{\text{ex}}} \mathbb{E}[Y_k \mid S = 1] + \sum_{k \notin K_{\text{ex}}} \big(\mathbb{E}[Y_k \mid S = 1] - \mathbb{E}[Y_k(0) \mid S = 1]\big).$$

El primer sumando se observa sin ningún supuesto de identificación; solo el segundo necesita las secciones 3 y 4. Un error e en $\theta_{\text{com}} = \sum_{k \notin K_{\text{ex}}} \mathbb{E}[Y_k(0) \mid S = 1]$ produce el mismo error en $\hat{L}$, así que la conclusión sobre L es poco sensible a fallos de (A2) o (A3) cuando θ_{com}/L es pequeño. Una parte estructural grande no basta por sí sola: con a_{ex} y a_{com} las

dos sumas de $\mathbb{E}[Y_k \mid S = 1]$ y $\rho = a_{\text{ex}}/L$, se tiene $\theta_{\text{com}}/L = a_{\text{com}}/L - (1-\rho)$, que puede ser grande aunque ρ se acerque a 1. Dos advertencias: si la unidad obtiene después la componente por otra vía, L es una cota superior de la pérdida para la organización; y con un resultado binario del tipo «compra algo» la descomposición no es aditiva, así que hay que trabajar con los indicadores por componente. El intercambio completo, que además inyecta en el canal premium un grupo procedente del básico, es la misma construcción con los papeles de los canales intercambiados.

3 Identificación como cambio de medida

Bajo (A1)–(A4), la media contrafactual θ es la media del resultado observado en el canal donante ponderada por $w = dP/dQ$. Ninguna parte del argumento usa densidades respecto de la medida de Lebesgue.

Teorema 1 (Identificación)**.** *Supongamos (A1)–(A4) y además* $\int_{\mathcal{X}} \mathbb{E}\big[|Y| \mid X = x, D = 0\big]\, P(dx) < \infty$. *Sea* $w = dP/dQ$, *que existe por (A3). Entonces*

$$\theta = \mathbb{E}\big[w(X)\, Y \mid D = 0\big] = \frac{\mathbb{E}[\tilde{w}(X)\, Y \mid D = 0]}{\mathbb{E}[\tilde{w}(X) \mid D = 0]} \qquad \text{para todo } \tilde{w} = c\, w,\ c > 0.$$

La condición adicional se cumple siempre que Y esté acotada.

Demostración. Paso 1 (torre). Como la ley de X condicionada a $S = 1$ es P, $\theta = \mathbb{E}[m_0^S(X) \mid S = 1] = \int m_0^S \,\mathrm{d}P$, finita por (A4), ya que $|m_0^S| \le \mathbb{E}[|Y(0)| \mid X, S = 1]$ P-casi seguro. *Paso 2 (intercambiabilidad).* Por (A2), $\theta = \int m_0 \,\mathrm{d}P$. *Paso 3 (Radon–Nikodym).* Por (A3) existe $w \ge 0$ medible con $P(A) = \int_A w \,\mathrm{d}Q$ para todo A. La fórmula de cambio de medida, válida para indicadores, para funciones simples por linealidad y para funciones no negativas por convergencia monótona, se extiende a toda g P-integrable: $\int g \,\mathrm{d}P = \int g\, w \,\mathrm{d}Q$. Con $g = m_0$, $\theta = \int m_0\, w \,\mathrm{d}Q$. *Paso 4 (vuelta a los datos).* La condición adicional equivale a $\mathbb{E}[w(X)|Y| \mid D = 0] < \infty$, así que $w(X)Y$ es integrable bajo $\mathbb{P}(\cdot \mid D = 0)$, y extrayendo lo conocido de la esperanza condicionada, $\mathbb{E}[w(X)Y \mid D = 0] = \mathbb{E}[w(X) m_0(X) \mid D = 0] = \int m_0\, w \,\mathrm{d}Q = \theta$. La forma autonormalizada se sigue de $\mathbb{E}[w(X) \mid D = 0] = \int w \,\mathrm{d}Q = P(\mathcal{X}) = 1$: el cociente vale θ para w y es invariante al multiplicar w por $c > 0$. □

Esta invarianza es la que permite, en la sección 4, usar pesos conocidos solo salvo una constante.

Ejemplo 1. Sean tres perfiles A, B y C con $Q = (0{,}5;\ 0{,}3;\ 0{,}2)$, $P = (0{,}1;\ 0{,}3;\ 0{,}6)$ y $m_0 = (4\,\%;\ 2\,\%;\ 0{,}5\,\%)$. La media ingenua del canal donante es 2,7 %, pero $\theta = 0{,}1 \cdot 4\,\% + 0{,}3 \cdot 2\,\% + 0{,}6 \cdot 0{,}5\,\% = 1{,}3\,\%$. Los pesos $w = P/Q = (0{,}2;\ 1;\ 3)$ la recuperan desde el canal donante: $0{,}5 \cdot 0{,}2 \cdot 4\,\% + 0{,}3 \cdot 1 \cdot 2\,\% + 0{,}2 \cdot 3 \cdot 0{,}5\,\% = 1{,}3\,\%$. La media ingenua duplica θ porque el canal donante tiene sobre todo perfiles A, que responden más.

Proposición 1 (Doble robustez)**.** *Bajo (A1)–(A4), sean* $\bar{w} \ge 0$ *y* $\bar{m}$ *medibles, con las integrales siguientes finitas, y*

$$\psi(\bar{w}, \bar{m}) = \mathbb{E}\big[\bar{w}(X)\,(Y - \bar{m}(X)) \mid D = 0\big] + \int \bar{m} \,\mathrm{d}P.$$

Entonces $\psi(\bar{w}, \bar{m}) - \theta = \int_{\mathcal{X}} (\bar{w} - w)(m_0 - \bar{m}) \,\mathrm{d}Q$. *En particular,* $\psi(\bar{w}, \bar{m}) = \theta$ *si* $\bar{w} = w$ *o* $\bar{m} = m_0$, *Q-casi seguro.*

Demostración. Por el paso 4 de la prueba anterior aplicado a $\bar{w}$, el primer sumando vale $\int \bar{w}(m_0 - \bar{m})\,\mathrm{d}Q$. Por el paso 3, $\int \bar{m}\,\mathrm{d}P - \theta = \int (\bar{m} - m_0)\,w\,\mathrm{d}Q$. Sumando se obtiene el resultado. □

El error es un producto de los dos errores de estimación. Esa estructura es la que permite tasas lentas en cada modelo y, aun así, normalidad a ritmo $\sqrt{n}$ (Teorema 5).

4 El clasificador identifica la derivada de Radon–Nikodym

Un clasificador calibrado que distingue el grupo objetivo del canal donante da w salvo una constante, y el conjunto donde ese clasificador está seguro, $\{p = 1\}$, es exactamente la parte del grupo objetivo sin soporte.

Construcción. Juntamos ambas poblaciones con una etiqueta: $(\tilde{X}, Z)$ con $Z \sim \text{Bernoulli}(\pi)$, $\pi \in (0,1)$, $\tilde{X} \mid Z = 1 \sim P$ y $\tilde{X} \mid Z = 0 \sim Q$. La ley de $\tilde{X}$ es la mezcla $M = \pi P + (1-\pi)Q$, y el clasificador ideal es una versión $p(x)$ de $\mathbb{P}(Z = 1 \mid \tilde{X} = x)$. En la práctica π es la fracción del grupo objetivo en la muestra combinada; no afecta al estimando.

Lema 1. *$P \ll M$ y $Q \ll M$, con $dP/dM = p/\pi$ y $dQ/dM = (1-p)/(1-\pi)$, M-casi seguro.*

Demostración. Si $M(A) = 0$, entonces $\pi P(A) + (1-\pi)Q(A) = 0$ y, como ambos coeficientes son positivos, $P(A) = Q(A) = 0$. Además, para todo $A \in \mathcal{A}$, $\pi P(A) = \mathbb{P}(Z = 1, \tilde{X} \in A) = \int_A p\,\mathrm{d}M$ por definición de esperanza condicionada; luego p/π es una versión de dP/dM. El caso de Q es idéntico con $1 - p$. □

Teorema 2 (Cociente de odds)**.** *Tomemos una versión de p con valores en $[0,1]$ y sea $r = \frac{1-\pi}{\pi}\,\frac{p}{1-p}$ sobre $\{p < 1\}$ y $r = 0$ sobre $\{p = 1\}$. Entonces $Q(\{p = 1\}) = 0$ y, para todo $A \in \mathcal{A}$, $\int_A r\,\mathrm{d}Q = P(A \cap \{p < 1\})$. En particular, bajo (A3), $r = dP/dQ$ Q-casi seguro.*

Demostración. Por el Lema 1, $Q(\{p = 1\}) = \int_{\{p=1\}} \frac{1-p}{1-\pi}\,\mathrm{d}M = 0$. Para $A \in \mathcal{A}$, por la regla de la cadena,

$$\int_A r\,\mathrm{d}Q = \int_{A \cap \{p<1\}} \frac{1-\pi}{\pi}\,\frac{p}{1-p}\cdot\frac{1-p}{1-\pi}\,\mathrm{d}M = \int_{A\cap\{p<1\}} \frac{p}{\pi}\,\mathrm{d}M = P(A \cap \{p < 1\}).$$

Bajo (A3), $P(\{p = 1\}) = 0$ porque $Q(\{p = 1\}) = 0$, así que $\int_A r\,\mathrm{d}Q = P(A)$ para todo A. □

Combinado con la invarianza del Teorema 1, bastan los odds $p/(1-p)$: la constante $(1-\pi)/\pi$ se cancela. Con un clasificador de log-odds F, el peso es e^F. El teorema exige que p sea la probabilidad condicional verdadera: un clasificador bien ordenado pero mal calibrado ordena bien a las unidades y aun así da pesos sesgados.

Ejemplo 1 (continuación). Con $\pi = 0{,}2$, el clasificador ideal vale $p = (0{,}048;\ 0{,}200;\ 0{,}429)$ en A, B y C, con odds $(0{,}05;\ 0{,}25;\ 0{,}75) = w/4$, y el estimador autonormalizado da 1,3 %. El clasificador $\tilde{p} = p^2$ ordena igual (mismo AUC), pero sus odds $(0{,}0023;\ 0{,}042;\ 0{,}225)$ dan 0,89 %, un sesgo del 32 %. La calibración importa, no solo la discriminación.

Teorema 3 (Soporte y descomposición de Lebesgue)**.** *Sin suponer (A3):*

1. *$P \ll Q$ si y solo si $P(\{p = 1\}) = 0$.*

2. *La descomposición de Lebesgue de P respecto de Q es $P = P_{\mathrm{ac}} + P_{\mathrm{s}}$, con $P_{\mathrm{ac}}(A) = P(A \cap \{p < 1\})$, $P_{\mathrm{s}}(A) = P(A \cap \{p = 1\})$ y $dP_{\mathrm{ac}}/dQ = r$.*
3. *Sea $\varepsilon = P(\{p = 1\})$. Si $\varepsilon < 1$, (A2) se cumple sobre $\{p < 1\}$ y $\int_{\{p<1\}} \mathbb{E}[|Y| \mid X = x, D = 0]\, P(dx) < \infty$, la ponderación autonormalizada con r recupera*

$$\frac{\mathbb{E}[r(X)\, Y \mid D = 0]}{\mathbb{E}[r(X) \mid D = 0]} = \theta_{\mathrm{ac}} := \mathbb{E}\big[Y(0) \mid S = 1,\, p(X) < 1\big],$$

y $\theta = (1 - \varepsilon)\theta_{\mathrm{ac}} + \varepsilon\, \theta_{\mathrm{s}}$, con $\theta_{\mathrm{s}} = \mathbb{E}[Y(0) \mid S = 1,\, p(X) = 1]$, definido cuando $\varepsilon > 0$, no identificado.

Demostración. (2) Por el Teorema 2, P_{ac} tiene densidad r respecto de Q, luego $P_{\mathrm{ac}} \ll Q$; P_{s} está concentrada en $\{p = 1\}$, que es Q-nulo, luego $P_{\mathrm{s}} \perp Q$; por la unicidad de la descomposición de Lebesgue, esta es la descomposición. El conjunto $\{p = 1\}$ depende de la versión de p solo módulo conjuntos M-nulos, que son nulos para P y para Q. (1) $P \ll Q$ si y solo si $P_{\mathrm{s}} = 0$. (3) Por el Teorema 2, $\mathbb{E}[r(X) \mid D = 0] = 1 - \varepsilon$; repitiendo los pasos 3 y 4 del Teorema 1 con P_{ac}, el numerador vale $\int_{\{p<1\}} m_0 \, \mathrm{d}P = (1 - \varepsilon)\theta_{\mathrm{ac}}$. La relación con θ es la ley de probabilidad total. □

Corolario 1 (Cotas de identificación parcial)**.** *Si $Y \in [0,1]$, entonces $(1 - \varepsilon)\theta_{\mathrm{ac}} \le \theta \le (1 - \varepsilon)\theta_{\mathrm{ac}} + \varepsilon$, y el sesgo de la ponderación es $\theta_{\mathrm{ac}} - \theta = \varepsilon(\theta_{\mathrm{ac}} - \theta_{\mathrm{s}})$.*

La anchura del intervalo es ε, que puede superar a la propia tasa cuando las tasas son pequeñas: si al Ejemplo 1 se añade un perfil sin soporte con $P = (0{,}1;\ 0{,}3;\ 0{,}5;\ 0{,}1)$, entonces $\varepsilon = 0{,}1$, $\theta_{\mathrm{ac}} = 1{,}39\,\%$ y el intervalo es $[1{,}25\,\%;\ 11{,}25\,\%]$. Solo es informativo con un supuesto adicional; por ejemplo, si las unidades sin soporte no responden mejor que el resto del grupo, $\theta_{\mathrm{s}} \le \theta_{\mathrm{ac}}$, el intervalo se reduce a $[(1 - \varepsilon)\theta_{\mathrm{ac}}, \theta_{\mathrm{ac}}]$, aquí $[1{,}25\,\%;\ 1{,}39\,\%]$, y el estimador ponderado es una cota superior de θ.

Corolario 2 (Estimador doblemente robusto sin soporte)**.** *Bajo las hipótesis del Teorema 3, sea $\bar{m}$ con $\bar{m} = m_0$ P-casi seguro sobre $\{p < 1\}$. Con los pesos r,*

$$\frac{\mathbb{E}[r(X)(Y - \bar{m}(X)) \mid D = 0]}{\mathbb{E}[r(X) \mid D = 0]} + \int \bar{m} \, \mathrm{d}P = (1 - \varepsilon)\theta_{\mathrm{ac}} + \varepsilon\, \mathbb{E}_P\big[\bar{m}(X) \mid p(X) = 1\big].$$

Demostración. Por el Teorema 2, el numerador del primer sumando es $\int_{\{p<1\}} (m_0 - \bar{m}) \, \mathrm{d}P = 0$. El segundo se parte en $\{p < 1\}$, donde integra $(1 - \varepsilon)\theta_{\mathrm{ac}}$, y $\{p = 1\}$, donde integra $\varepsilon\, \mathbb{E}_P[\bar{m} \mid p = 1]$. □

A diferencia del estimador ponderado, que se queda con la parte con soporte, el doblemente robusto rellena la parte sin soporte con la extrapolación del modelo de resultado. Recupera θ si y solo si esa extrapolación acierta en media, $\mathbb{E}_P[\bar{m} \mid p = 1] = \theta_{\mathrm{s}}$, que es un supuesto adicional no contrastable. Ma y Namkoong (2025) proponen hacerla explícita bajo un supuesto de suavidad y acotar su efecto con un análisis de sensibilidad.

Lectura práctica. En muestra finita nunca se observa $\hat{p} = 1$ exactamente. Un diagnóstico natural es la masa estimada $\hat{P}(\hat{p} > 1 - \delta)$ para δ pequeño; un AUC cercano a 1 es una señal de alarma, porque indica que P y Q están cerca de ser mutuamente singulares, no que el clasificador sea bueno.

5 Grupo objetivo definido por un corte conocido

En el caso típico, el grupo objetivo es un corte en una puntuación que la organización conoce, $S = D \cdot \mathbf{1}\{s(X) \le c\}$. Entonces no hace falta un clasificador que distinga el grupo objetivo del canal donante: basta la propensión de canal ordinaria, con el corte impuesto a mano.

Proposición 2 (Pesos con corte conocido)**.** *Sea $S = D \cdot \mathbf{1}\{s(X) \le c\}$, con s medible y conocida, y sea e una versión de $\mathbb{P}(D = 1 \mid X)$. Bajo (A3), existe $k > 0$ tal que*

$$\frac{dP}{dQ}(x) = k\,\mathbf{1}\{s(x) \le c\}\,\frac{e(x)}{1 - e(x)} \qquad Q\text{-casi seguro.}$$

Demostración. Sea μ la ley de X en la población. Como $s(X)$ es función de X, $\mathbb{P}(S = 1 \mid X) = \mathbf{1}\{s(X) \le c\}\,e(X)$. Por la definición de probabilidad condicionada, $P(A) = \int_A \mathbf{1}\{s \le c\}\,e\,\mathrm{d}\mu/\mathbb{P}(S = 1)$ y $Q(A) = \int_A (1 - e)\,\mathrm{d}\mu/\mathbb{P}(D = 0)$ para todo $A \in \mathcal{A}$, así que P y Q son absolutamente continuas respecto de μ, con densidades proporcionales a $\mathbf{1}\{s \le c\}\,e$ y a $1 - e$. El conjunto $\{e = 1\}$ es Q-nulo, y fuera de él, bajo (A3), la regla de la cadena da $dP/dQ = (dP/d\mu)/(dQ/d\mu) = k\,\mathbf{1}\{s \le c\}\,e/(1 - e)$, con $k = \mathbb{P}(D = 0)/\mathbb{P}(S = 1)$. □

La identidad es elemental, pero cambia el problema de estimación. El clasificador del Teorema 2 tiene que aprender un salto nítido en $\{s = c\}$, con los pocos casos del grupo objetivo como positivos. La propensión de canal suele ser una función suave y se estima con todas las unidades del canal premium. La constante k se cancela al normalizar, y el diagnóstico de soporte del Teorema 3 se lee en $\hat{e}$: falta soporte donde $\hat{e} \to 1$ dentro de $\{s \le c\}$. El Lema 3 es la misma identidad aplicada a (X,U).

Relación con la literatura. La identidad no es nueva en sustancia. En el análisis por subgrupos con puntuaciones de propensión es práctica habitual estimar la propensión en toda la cohorte y aplicarla dentro del subgrupo (Rassen et al., 2012), y Dong et al. (2020) estudian cuándo conviene ese modelo y cuándo uno ajustado en cada subgrupo, que equilibra mejor dentro del subgrupo a costa de más varianza. Lo que añadimos es la comparación con el clasificador «grupo objetivo frente a donantes», el habitual cuando el cambio de medida se plantea como estimación de un cociente de densidades (Bickel et al., 2009; Sugiyama et al., 2012), en el caso en que el grupo objetivo es un corte en una puntuación de las propias covariables. Con modelos flexibles, los dos enfoques son consistentes y las diferencias son de muestra finita, pero afectan a cosas que la literatura de subgrupos no examina: el signo del recorte, el tamaño muestral efectivo y la validez del bootstrap (sección 10.3).

6 Variables de canal y medición distinta

Una covariable que solo se registra en uno de los canales rompe el soporte aunque las unidades sean comparables. Si no predice el resultado dadas las demás, descartarla restaura la identificación; si confunde, ni usarla ni descartarla identifica θ.

Modelo de medición. Cada unidad tiene covariables latentes $X^* = (V,C^*)$, donde C^* toma valores en $\mathcal{C} \cup \{\varnothing\}$ y $C^* = \varnothing$ significa «sin dato real». Lo registrado depende del canal: $X = (V,C)$, con $C = C^*$ si $D = 1$ y $C = \varnothing$ si $D = 0$. Más en general, $X = \varphi_D(X^*)$ con instrumentos de medida distintos, $\varphi_0 \neq \varphi_1$. Ejemplos: un historial comercial que solo guardan los gestores

del canal premium, o pruebas diagnósticas que solo se hacen en el hospital. Escribimos P^* y Q^* para las leyes de X^* en el grupo objetivo y en el canal donante.

Lema 2 (Masa singular)**.** $\varepsilon = P_{\mathrm{s}}(\mathcal{X}) = \sup\{P(B) : B \in \mathcal{A}, Q(B) = 0\}$.

Demostración. Sea N un conjunto Q-nulo donde se concentra P_{s}. Para todo B con $Q(B) = 0$, $P_{\mathrm{ac}}(B) = 0$, porque $P_{\mathrm{ac}} \ll Q$; luego $P(B) = P_{\mathrm{s}}(B) \leq P_{\mathrm{s}}(\mathcal{X})$. Además $P(N) = P_{\mathrm{ac}}(N) + P_{\mathrm{s}}(N) = P_{\mathrm{s}}(\mathcal{X})$, así que el supremo se alcanza en N. □

Proposición 3 (Una variable de canal rompe el soporte)**.** *Bajo el modelo de medición, sea* $\kappa = \mathbb{P}(C^* \neq \varnothing \mid S = 1)$ *la fracción del grupo objetivo con dato real. Entonces* $\varepsilon \geq \kappa$*, y el clasificador ideal vale* $p = 1$ *M-casi seguro en los perfiles con* $C \neq \varnothing$*. Si* $\kappa > 0$*, (A3) falla con independencia de cómo sean las unidades.*

Demostración. Sea $B = \mathcal{V} \times \mathcal{C}$, el conjunto de perfiles con dato registrado. Por el modelo de medición, $Q(B) = \mathbb{P}(C \neq \varnothing \mid D = 0) = 0$, mientras que $P(B) = \kappa$; el Lema 2 da $\varepsilon \geq \kappa$. Como $\mathbb{P}(Z = 0, \tilde{X} \in B) = (1 - \pi)Q(B) = 0$, $p = 1$ M-casi seguro sobre B. □

Proposición 4 (Descartar una variable que no predice el resultado)**.** *Supongamos:*

1. Soporte latente: $P^* \ll Q^*$.
2. (A2) latente: $\mathbb{E}[Y(0) \mid X^*, S = 1] = \mathbb{E}[Y(0) \mid X^*, D = 0]$, *$P^*$-casi seguro.*
3. C^* no predice el resultado en el canal básico dado V: $\mathbb{E}[Y(0) \mid X^*, D = 0] = \mathbb{E}[Y(0) \mid V, D = 0]$, *$Q^*$-casi seguro.*

Entonces, con V como únicas covariables, (a) $P_V \ll Q_V$ y (b) $\mathbb{E}[Y(0) \mid V, S = 1] = \mathbb{E}[Y(0) \mid V, D = 0]$ P_V-casi seguro, así que los Teoremas 1–3 se aplican con $X = V$.

Demostración. (a) Si $Q_V(A) = 0$, entonces $Q^*(A \times (\mathcal{C} \cup \{\varnothing\})) = 0$, y por (1) también $P^*(A \times (\mathcal{C} \cup \{\varnothing\})) = P_V(A) = 0$. (b) Sea g una versión de $\mathbb{E}[Y(0) \mid V, D = 0]$. Por (3), $\mathbb{E}[Y(0) \mid X^*, D = 0] = g(V)$ salvo en un conjunto Q^*-nulo, que por (1) es también P^*-nulo. Por (2), $\mathbb{E}[Y(0) \mid X^*, S = 1] = g(V)$ P^*-casi seguro, y como V es función de X^*, la torre dentro de $\{S = 1\}$ da $\mathbb{E}[Y(0) \mid V, S = 1] = g(V)$. □

La condición (3) es un criterio de selección de covariables por el lado del resultado (de Luna et al., 2011; VanderWeele y Shpitser, 2011): basta aunque C^* esté asociada al canal.

Cuando la variable sí confunde. Si se mantienen (1) y (2) pero falla (3), sea $\mu^*(x^*) = \mathbb{E}[Y(0) \mid X^* = x^*, D = 0]$; entonces $\theta = \int \mu^* \, \mathrm{d}P^*$. Usando solo V, el estimador converge a $\int g \, \mathrm{d}P_V = \int g(v) \, \mathrm{d}P^*$, y su sesgo es

$$\int g \, \mathrm{d}P_V - \theta = -\int_{\mathcal{X}^*} (\mu^* - g) \, \mathrm{d}P^*.$$

Bajo Q^* esa integral es cero por definición de g. Bajo P^* solo puede ser distinta de cero si C^* predice $Y(0)$ dado V y además su distribución dado V difiere entre grupos: son las dos condiciones de la definición clásica de confusor, necesarias pero no suficientes, porque los efectos podrían compensarse. La condición exacta para que no haya sesgo es $\mathbb{E}_{P^*}[\mu^* - g \mid V] = 0$ P_V-casi seguro; (3) es una condición suficiente que no depende de P^*. Cuando el sesgo no es nulo, ninguna de las dos opciones identifica θ: sin C falla (A2), y con C falla (A3) y, como se ve a continuación, en general también (A2) en la parte con soporte. Por eso tampoco sirven las cotas del Corolario 1, que suponen (A2) en esa parte. Lo que queda es un análisis de sensibilidad sobre (3).

Conservar la variable tampoco arregla la parte con soporte. Con C entre las covariables, la parte con soporte es $\{C = \varnothing\}$. Pero «$\varnothing$» no significa lo mismo en los dos grupos: en el canal donante mezcla unidades con $C^* = \varnothing$ y con $C^* \neq \varnothing$, porque ahí nunca se registra; en el grupo objetivo equivale a $C^* = \varnothing$. Como todo el canal donante tiene $C = \varnothing$, $m_0(v,\varnothing) = g(v)$, y el estimador ponderado converge a $\mathbb{E}_{P^*}[g(V) \mid C^* = \varnothing]$, que en general no es ni θ ni θ_{ac}: (A2) en $\{C = \varnothing\}$ exige $\mu^*(V,\varnothing) = g(V)$ P-casi seguro, es decir, que entre los donantes con el mismo V respondan igual en el canal básico los que tienen historial y los que no; (3) lo implica, pero es más débil. El doblemente robusto, además, extrapola el modelo de resultado a las unidades con dato (Corolario 2). Ese modelo se entrena en el canal donante, donde C nunca varía; si no depende de C fuera del soporte, como ocurre con árboles, que no pueden partir por una variable constante en el entrenamiento, extrapola $g(V)$, y el doblemente robusto converge a $\mathbb{E}_{P^*}[g(V)]$, como si C no se usara.

Contrastabilidad. La condición (3) concierne a $Y(0)$ en el canal básico, donde C^* no se observa, así que no es contrastable directamente. Que C prediga el resultado en el canal premium es un indicio pero no una prueba, porque ahí se observa $Y(1)$.

Relación con el enfoque por patrón de ausencia. D'Agostino y Rubin (2000) y Blake et al. (2020) estiman la propensión dentro de cada patrón de valores ausentes y exigen que la variable parcialmente observada no confunda en el patrón donde falta. Una variable de canal es el caso en que el patrón lo determina el tratamiento: en el patrón observado no hay unidades donantes (Proposición 3), y en el ausente exige $\mu^*(V,\varnothing) = g(V)$, que (3) implica.

Diagnóstico práctico. Retirar una variable de canal debe reducir de forma visible el AUC del clasificador y la masa estimada $\hat{P}(\hat{p} > 1 - \delta)$; un salto grande en esa masa al incluir una variable es la firma de la Proposición 3.

6.1 Instrumentos de medida distintos

Una variable ausente en un canal es el caso más visible de un problema general: cada canal mide con su propio instrumento. Sea X^* la covariable latente, con valores en un espacio estándar de Borel $\mathcal{X}^*$, y sean P^* y Q^* sus leyes en el grupo objetivo y en el canal donante. Cada canal registra $X = \varphi_D(X^*)$, con $\varphi_0,\varphi_1 \colon \mathcal{X}^* \to \mathcal{X}$ medibles, de modo que $P = P^* \circ \varphi_1^{-1}$ y $Q = Q^* \circ \varphi_0^{-1}$. Sea $\mu^*(x^*) = \mathbb{E}[Y(0) \mid X^* = x^*, D = 0]$.

Teorema 4 (Instrumentos de medida distintos)**.** *Supongamos (A1), soporte latente $P^* \ll Q^*$ y (A2) latente: $\mathbb{E}[Y(0) \mid X^*, S = 1] = \mu^*(X^*)$ P^*-casi seguro.*

1. Variables comunes. *Para toda ψ medible, $P^* \circ \psi^{-1} \ll Q^* \circ \psi^{-1}$. En particular, si $\psi \circ \varphi_0 = \psi \circ \varphi_1 = k$ (variables que ambos canales miden igual), las leyes de $K = \psi(X)$ en los dos grupos cumplen $P_K \ll Q_K$.*
2. Identificación con las variables comunes. *Si además $\mu^*(X^*) = \mathbb{E}[Y(0) \mid K, D = 0]$ Q^*-casi seguro, los Teoremas 1–3 se aplican con K como covariables.*
3. Medición distinta con soporte. *Si φ_0 es inyectiva y $P \ll Q$ (en espacios estándar de Borel, φ_0 tiene entonces imagen boreliana e inversa medible por el teorema de Lusin–Souslin, y $\varphi_1(X^*)$ está en esa imagen P^*-casi seguro porque Q se concentra en ella), el estimador ponderado con X converge a*

$$\theta_X = \int_{\mathcal{X}^*} \mu^*\big(\varphi_0^{-1}(\varphi_1(x^*))\big)\, P^*(dx^*), \qquad \theta_X - \theta = \int_{\mathcal{X}^*} \left[\mu^* \circ \varphi_0^{-1} \circ \varphi_1 - \mu^*\right] \mathrm{d}P^*.$$

4. Indistinguibilidad. *En las condiciones de 3, existe un mundo sin error de medición, con $\varphi_1 = \varphi_0$ y la ley latente del grupo objetivo igual a $P^* \circ (\varphi_0^{-1} \circ \varphi_1)^{-1}$, que reproduce la ley de todo lo observado, cumple los supuestos mantenidos y en el que $\theta = \theta_X$. Ningún procedimiento basado solo en los datos observados distingue θ de θ_X.*

Demostración. (1) Si $Q^*(\psi^{-1}(B)) = 0$, por el soporte latente $P^*(\psi^{-1}(B)) = 0$. Si $\psi \circ \varphi_0 = \psi \circ \varphi_1 = k$, entonces $K = k(X^*)$ en los dos canales, y basta aplicar lo anterior con $\psi = k$.

(2) Es la Proposición 4 con $V = K$, que es función de X^*.

(3) En el canal donante, $X = \varphi_0(X^*)$ y φ_0 es inyectiva con inversa medible, así que condicionar en X equivale a condicionar en X^*; por (A1), $m_0(x) = \mu^*(\varphi_0^{-1}(x))$ Q-casi seguro, y como $P \ll Q$ esta versión queda fijada P-casi seguro. El estimador ponderado converge a $\int m_0 \, \mathrm{d}P$ (Teorema 1, que para esta convergencia solo usa $P \ll Q$), y por el cambio de variables de la medida imagen, $\int m_0 \, \mathrm{d}P = \int m_0(\varphi_1(x^*)) \, P^*(dx^*) = \theta_X$. Por (A2) latente y la torre, $\theta = \int \mu^* \, \mathrm{d}P^*$.

(4) En el mundo alternativo, el canal donante no cambia. El grupo objetivo se registra con φ_0 y su ley latente es $\tilde{P}^* = P^* \circ (\varphi_0^{-1} \circ \varphi_1)^{-1}$, así que su ley observada es $P^* \circ (\varphi_0 \circ \varphi_0^{-1} \circ \varphi_1)^{-1} = P^* \circ \varphi_1^{-1} = P$, la misma que en el mundo real. Para su resultado observado basta tomar, dado X, la misma ley condicional que en el mundo real, y con (A2) latente su respuesta en el canal básico es μ^*; su θ es $\int \mu^* \, \mathrm{d}\tilde{P}^* = \theta_X$. El mundo alternativo cumple los supuestos: como φ_0 es inyectiva, $Q^*(A) = Q(\varphi_0(A))$ y $\tilde{P}^*(A) = P(\varphi_0(A))$, así que $P \ll Q$ da $\tilde{P}^* \ll Q^*$, y (A2) latente vale por construcción. Las unidades premium que no están en el grupo objetivo se tratan igual, transformando su ley latente por $\varphi_0^{-1} \circ \varphi_1$. □

Lectura. Una variable medida de forma distinta es más peligrosa que una ausente. La ausente rompe el soporte y deja huella: el clasificador está seguro, $p = 1$, y $\hat{\varepsilon} > 0$. La medida de forma distinta puede conservar el soporte, y el clasificador interpreta la diferencia de medida como una diferencia real entre unidades. En un ejemplo con $P^* = N(1; 1)$, $Q^* = N(0; 1)$, $\mu^*(x) = \sigma(-3 - 0{,}8x)$ y un canal premium que registra la variable desplazada en c, un desplazamiento de $c = \pm 0{,}3$ desviaciones típicas produce sesgos de $-20{,}5\,\%$ y $+25{,}4\,\%$ sobre $\theta = 2{,}92\,\%$. Con clasificador logístico, el estimador coincide con θ_X ($z = +0{,}6$ en ambos casos). El AUC cambia (0,76 sin error; 0,82 y 0,69 con él), pero de una forma que también produciría una diferencia real de población. La única salida es información externa al diseño: unidades medidas con ambos instrumentos, por ejemplo clientes que cambiaron de canal, que permiten estimar $\varphi_0^{-1} \circ \varphi_1$.

7 Estimación e inferencia

Muestreo. Observamos una muestra combinada i.i.d. $O_i = (Z_i, X_i, (1 - Z_i)Y_i)$, $i = 1, \ldots, n$, con $\mathbb{P}(Z = 1) = \pi$, $X \mid Z = 1 \sim P$ y $X \mid Z = 0 \sim Q$; para θ solo hace falta el resultado de las unidades donantes. Cuando una unidad (un cliente) genera varias observaciones (llamadas), O_i es el bloque completo de esa unidad y todo lo que sigue se aplica a nivel de unidad. Suponemos que el canal y la pertenencia al grupo objetivo son propiedades de la unidad, constantes entre sus observaciones, y que P, Q, m_0 y θ se definen a nivel de observación, de modo que cada unidad pesa según su número de observaciones. Si ese número depende de $Y(0)$ dado X, los estimandos por unidad y por observación, y las versiones correspondientes de (A2), difieren.

Estimadores. Con $\hat{o} = \hat{p}/(1-\hat{p})$ y n_1 el número de observaciones del grupo objetivo,

$$\hat{\theta}_{\mathrm{H}} = \frac{\sum_{i:Z_i=0} \hat{o}(X_i)\, Y_i}{\sum_{i:Z_i=0} \hat{o}(X_i)}, \qquad \hat{\theta}_{\mathrm{DR}} = \frac{\sum_{i:Z_i=0} \hat{o}(X_i)\,(Y_i - \hat{m}(X_i))}{\sum_{i:Z_i=0} \hat{o}(X_i)} + \frac{1}{n_1} \sum_{i:Z_i=1} \hat{m}(X_i).$$

El primero es el estimador ponderado de Hájek y el segundo, la versión muestral de ψ en la Proposición 1 con el término de pesos normalizado. Ambos usan *cross-fitting*: las unidades se reparten en K bloques y, para las observaciones del bloque k, $\hat{p}$ y $\hat{m}$ se entrenan con los demás. Con un corte conocido, $\hat{o}$ se sustituye por $\mathbf{1}\{s \le c\}\,\hat{e}/(1-\hat{e})$ (Proposición 2), y la muestra incluye también las unidades premium de fuera del grupo objetivo. Con muestreo poblacional de (D,S,X,Y), la función de influencia correspondiente es $\mathbb{P}(S=1)^{-1}\big[S(m_0 - \theta) + (1-D)\,\mathbf{1}\{s \le c\}\,e/(1-e)\,(Y - m_0)\big]$; esperamos un análogo del Teorema 5, pero no lo demostramos.

7.1 Recorte de pesos

Recortar los pesos cambia el estimando. Para $\tau > 0$, sean $w_\tau = \min(w,\tau)$ y $\varphi_\tau(t) = \min(1,\tau/t)$ para $t > 0$. Con los pesos verdaderos, el estimador autonormalizado recortado converge a

$$\theta_\tau = \frac{\mathbb{E}[w_\tau(X)\,Y \mid D=0]}{\mathbb{E}[w_\tau(X) \mid D=0]}.$$

Proposición 5 (Sesgo del recorte)**.** *Bajo (A1)–(A4):*

1. $\theta_\tau - \theta = \dfrac{\mathrm{Cov}_P\big(m_0(X),\varphi_\tau(w(X))\big)}{\mathbb{E}_P[\varphi_\tau(w(X))]}$.
2. *Si $g(t) = \mathbb{E}_P[m_0(X) \mid w(X)=t]$ admite una versión no creciente, $\theta_\tau \ge \theta$; si admite una no decreciente, $\theta_\tau \le \theta$.*
3. *Si $Y \ge 0$, la versión sin normalizar está siempre por debajo: $\mathbb{E}[w_\tau(X)\,Y \mid D=0] \le \theta$.*

Demostración. Como $P(\{w=0\}) = \int_{\{w=0\}} w \,\mathrm{d}Q = 0$, sobre $\{w>0\}$ se tiene $w_\tau = \varphi_\tau(w)\,w$. Por la torre y el cambio de medida, $\mathbb{E}[w_\tau(X)Y \mid D=0] = \int w_\tau m_0 \,\mathrm{d}Q = \mathbb{E}_P[\varphi_\tau(w)\,m_0]$ y $\mathbb{E}[w_\tau(X) \mid D=0] = \mathbb{E}_P[\varphi_\tau(w)] \in (0,1]$; restando $\theta = \mathbb{E}_P[m_0]$ se obtiene (1). Para (2), la torre da $\mathrm{Cov}_P(m_0,\varphi_\tau(w)) = \mathrm{Cov}_P(g(T),\varphi_\tau(T))$ con $T = w(X)$. La función φ_τ es no creciente; si g también lo es, $(g(T)-g(T'))(\varphi_\tau(T)-\varphi_\tau(T')) \ge 0$ para una copia independiente T', y su esperanza es $2\,\mathrm{Cov}_P(g(T),\varphi_\tau(T))$ (desigualdad de asociación de Chebyshev); el caso no decreciente es simétrico. Para (3), $\varphi_\tau \le 1$ y $m_0 \ge 0$ dan $\mathbb{E}_P[\varphi_\tau(w)m_0] \le \theta$. □

Interpretación. $w(x)$ grande significa que el perfil x es mucho más frecuente en el grupo objetivo que en el canal donante. No hay un sentido por defecto: depende de si, dentro del grupo objetivo, los perfiles más típicos del canal premium responden más o menos en el canal básico. Si responden menos, g es decreciente y el recorte sobreestima θ y, por tanto, infraestima la pérdida; en nuestra simulación responden más (sección 10.2). La condición trata de g como función del peso, no de X, y es aproximadamente comprobable, porque m_0 está identificada en el soporte.

Ejemplo 1 (recorte). Con $\tau = 2$, los pesos $(0{,}2;\ 1;\ 3)$ pasan a $(0{,}2;\ 1;\ 2)$ y $\theta_\tau = 1{,}2\,\%/0{,}8 = 1{,}5\,\%$, frente a $\theta = 1{,}3\,\%$. La fórmula da lo mismo: $\varphi_\tau = (1;\ 1;\ 2/3)$, $\mathbb{E}_P[\varphi_\tau] = 0{,}8$ y la covarianza vale 0,16 puntos, así que el sesgo es 0,2 puntos. La versión sin normalizar da 1,2 %, por debajo de θ.

Corolario 3 (Recorte con el estimador doblemente robusto)**.** *Por la Proposición 1 con* $\bar{w} = w_\tau$, $\psi(w_\tau,\bar{m}) - \theta = -\int_{\{w>\tau\}}(w-\tau)(m_0-\bar{m})\,\mathrm{d}Q$.

El corolario se refiere a la forma no normalizada ψ: el recorte solo sesga en la medida en que el modelo de resultado se equivoca en la región recortada. Para la forma normalizada que usamos, el sesgo es $\mathbb{E}_Q[w_\tau(m_0-\bar{m})]/\mathbb{E}_Q[w_\tau] - \mathbb{E}_P[m_0-\bar{m}]$, que se anula si $\bar{m} = m_0$ en todo el soporte, pero no necesariamente si el modelo solo acierta en la región recortada. Como la Proposición 1 vale para cualesquiera pesos, al recortar pesos estimados el sesgo depende de los dos errores, y se anula si $\bar{m} = m_0$.

Pesos estimados. En la práctica se recorta $\hat{w}$, y el recorte elimina a la vez peso verdadero y ruido de estimación, así que el signo de la Proposición 5 no está garantizado. En la nota complementaria, incluida en el repositorio que acompaña al artículo, demostramos que se conserva si el error de estimación es un ruido multiplicativo independiente del perfil con densidad log-cóncava. Antes de recortar, el efecto del recorte calculado con $\hat{m}$ en lugar de Y, o $\hat{m}$ por deciles de masa de $\hat{w}$, indica en qué sentido empujará. Crump et al. (2009) recortan por la propensión y redefinen el estimando; Ma y Wang (2020) mantienen el estimando y caracterizan el sesgo del recorte por descarte en el estimador sin normalizar, del que el punto 3 es la versión para el recorte por tope; la aportación de la Proposición 5 es el caso normalizado, con su fórmula exacta. Liu et al. (2023) tratan el truncamiento como un cambio de estimando para el efecto sobre los tratados.

7.2 Varianza y normalidad asintótica

Función de influencia. Sean $o = p/(1-p)$ y $\sigma^2(x) = \mathrm{Var}(Y \mid X = x, D = 0)$. La función de influencia del estimador doblemente robusto, con la misma forma que la eficiente para la media contrafactual de los tratados (Hahn, 1998), es

$$\phi(O) = \frac{1}{\pi}\Big[Z\,(m_0(X)-\theta) + (1-Z)\,o(X)\,(Y-m_0(X))\Big],$$
$$V = \mathbb{E}[\phi^2] = \frac{\mathrm{Var}_P(m_0(X))}{\pi} + \frac{\mathbb{E}_Q[w(X)^2\sigma^2(X)]}{1-\pi},$$

donde el término cruzado se anula porque $Z(1-Z) = 0$ y el segundo sumando usa $o = \pi w/(1-\pi)$ (Teorema 2).

Proposición 6 (Cuándo la varianza es finita)**.** *Si* Y *está acotada y* $0 < \sigma_-^2 \le \sigma^2 \le \sigma_+^2$ Q*-casi seguro, entonces* $V < \infty$ *si y solo si* $\mathbb{E}_Q[w^2] < \infty$*, es decir, si y solo si* $\chi^2(P\|Q) = \mathbb{E}_Q[w^2] - 1 < \infty$*. La continuidad absoluta* $P \ll Q$ *no implica esa condición.*

Demostración. El primer sumando de V es finito porque m_0 está acotada; el segundo está entre $\sigma_-^2\,\mathbb{E}_Q[w^2]/(1-\pi)$ y $\sigma_+^2\,\mathbb{E}_Q[w^2]/(1-\pi)$. Para ver que $P \ll Q$ no basta, sea Q uniforme en $(0,1)$ y $w(x) = x^{-1/2}/2$, que integra 1; entonces $P \ll Q$ pero $\mathbb{E}_Q[w^2] = \int_0^1 (4x)^{-1}dx = \infty$. □

Así, (A3) basta para identificar θ, pero no para estimarla a ritmo $n^{-1/2}$: con la varianza condicional acotada inferiormente, hace falta además $\chi^2(P\|Q) < \infty$, y la teoría estándar exige algo más fuerte, pesos acotados.

Tamaño muestral efectivo. El de Kish, $n_{\text{eff}} = (\sum_i \hat{w}_i)^2 / \sum_i \hat{w}_i^2$ sobre las n_0 observaciones donantes, cumple con los pesos verdaderos $n_{\text{eff}}/n_0 \to 1/\mathbb{E}_Q[w^2] = 1/(1+\chi^2(P\|Q))$, así que estima la divergencia χ^2; con pesos estimados puede moverse en los dos sentidos (el ruido de $\hat{w}$ lo reduce y el encogimiento de un clasificador regularizado lo aumenta), y en nuestra simulación queda por debajo del teórico. En muestra finita siempre es finito, incluso cuando $\chi^2 = \infty$, y entonces tiende a cero muy despacio y con mucho ruido: en el contraejemplo de la Proposición 6, la mediana sobre réplicas pasa de 0,45 con $n_0 = 10^3$ a unos 0,21 con $n_0 = 10^7$, y con $n_0 = 10^3$ los percentiles 1 y 99 entre réplicas son 0,05 y 0,65. Un n_{eff} razonable no garantiza que χ^2 sea finita; conviene examinar además la estabilidad de los cuantiles altos de $\hat{w}$.

Teorema 5 (Normalidad asintótica del estimador doblemente robusto)**.** *Supongamos (A1)–(A4), Y acotada y además:*

1. Solapamiento fuerte: $p(X) \le 1-\eta$ *Q-casi seguro para algún $\eta > 0$, es decir, w acotada.*
2. Cross-fitting *por unidad en un número fijo K de bloques de tamaño proporcional a n, con $\hat{p} \le 1-\eta$ y $\hat{m}$ acotada por las mismas cotas que Y.*
3. Tasas: $r_o = \max_k \|\hat{o}_k - o\|$ *y* $r_m = \max_k \|\hat{m}_k - m_0\|$ *en $L^2(Q)$ tienden a 0 en probabilidad, y $r_o\, r_m = o_P(n^{-1/2})$.*

Entonces $\sqrt{n}(\hat{\theta}_{\text{DR}} - \theta) \to N(0,V)$ en distribución, y la media muestral de $\hat{\phi}(O_i)^2$ estima V de forma consistente.

La prueba, en el apéndice A, es una adaptación del Teorema 3.1 de Chernozhukov et al. (2018) y de su ejemplo del efecto sobre los tratados: por la Proposición 1, el sesgo es bilineal en los errores de los parámetros auxiliares (ortogonalidad de Neyman), el *cross-fitting* controla el término de proceso empírico sin condiciones de complejidad, y el denominador se trata con el método delta.

Más allá del solapamiento fuerte. La condición 1 es más fuerte que (A3) y que $\chi^2 < \infty$. Si los pesos no están acotados pero $\chi^2 < \infty$, V es finita, aunque la prueba estándar no cubre el caso. Si $\chi^2 = \infty$ y la varianza condicional está acotada inferiormente, ningún estimador regular converge a ritmo $\sqrt{n}$: es el caso de identificación irregular de Khan y Tamer (2010). Ma y Wang (2020) muestran que entonces el límite puede ser no normal y proponen inferencia por submuestreo, y Ma et al. (2023) dan inferencia adaptativa para estimadores doblemente robustos con recorte y corrección de sesgo. Nuestra simulación está en ese régimen: el índice de canal no está acotado dentro de la región objetivo, así que los pesos no están acotados aunque χ^2 sea finita, y la implementación recorta $\hat{p}$ a $[10^{-6}, 1-10^{-6}]$ en lugar de a $1-\eta$; sus coberturas son evidencia fuera de las condiciones del Teorema 5.

Intervalos. Usamos $\hat{\theta}_{\text{DR}} \pm 1{,}96\,(\hat{V}/n)^{1/2}$. El Teorema 5 no cubre el recorte de pesos ni el bootstrap, que evaluamos en la simulación (secciones 10.2 y 10.5). Si el grupo objetivo se define con un umbral estimado $\hat{c}$, su incertidumbre añade un término a V que no incluimos: tratamos la regla de selección como fija.

8 Sensibilidad a la confusión no observada

Si falla (A2), θ deja de estar identificado. El modelo de sensibilidad marginal acota cuánto puede alejarse θ del valor identificado en función de un único parámetro $\Lambda \ge 1$.

Modelo. Seguimos a Tan (2006) y Dorn y Guo (2023); Zhao et al. (2019) dan intervalos de sensibilidad para estimadores ponderados bajo este modelo mediante el bootstrap de percentiles. Supongamos que hay una variable no observada U tal que la intercambiabilidad vale dado (X,U): $\mathbb{E}[Y(0) \mid X,U,S=1] = \mathbb{E}[Y(0) \mid X,U,D=0]$. En la muestra combinada de la sección 4, sea $\lambda(X,U)$ el cociente entre los odds de pertenecer al grupo objetivo dado (X,U) y dado X solo. El modelo MSM(Λ) supone $\Lambda^{-1} \le \lambda(X,U) \le \Lambda$: conocer U puede multiplicar o dividir esos odds como mucho por Λ. Con $\Lambda = 1$ se recupera (A2).

Proposición 7 (Cotas de sensibilidad)**.** *Supongamos (A1), (A3), (A4), $Y \ge 0$ y MSM(Λ), y sea $\theta_0 = \int m_0 \, \mathrm{d}P$ el valor identificado bajo (A2).*

1. Validez. $\theta \in [\theta_0/\Lambda,\ \Lambda\theta_0]$.
2. Exactitud para resultados raros. *Si además $\mathbb{P}(Y > 0 \mid X,D=0) \le 1/(1+\Lambda)$ Q-casi seguro, las dos cotas se alcanzan: existe un mundo compatible con MSM(Λ) y con todo lo observado en el que $\theta = \Lambda\theta_0$, y otro en el que $\theta = \theta_0/\Lambda$.*
3. Caso binario general. *Para $Y \in \{0,1\}$ con $m = m_0(x)$, las cotas exactas integran respecto de P los valores* $\min\big(\Lambda m, 1-(1-m)/\Lambda\big)$ *(superior) y* $\max\big(m/\Lambda, 1-\Lambda(1-m)\big)$ *(inferior); es la regla del cuantil de Dorn y Guo (2023) trasladada a θ.*

Demostración. Por Bayes, $\lambda(x,\cdot)$ es la densidad de la ley de U dado $X = x$ en el grupo objetivo respecto de la del canal donante, así que $\mathbb{E}_Q[\lambda \mid X] = 1$, y la derivada de la ley de (X,U) en el grupo objetivo respecto de la del donante es $w(X)\,\lambda(X,U)$. Aplicando el Teorema 1 a (X,U), $\theta = \mathbb{E}_Q[w(X)\,\mathbb{E}_Q(\lambda Y \mid X)]$.

(1) Como $Y \ge 0$ y $\Lambda^{-1} \le \lambda \le \Lambda$, $m_0(X)/\Lambda \le \mathbb{E}_Q[\lambda Y \mid X] \le \Lambda m_0(X)$; se integra contra $w\,\mathrm{d}Q$.

(2) Sea $\pi_+(X) = \mathbb{P}(Y > 0 \mid X,D=0)$. Para la cota superior, tómese $U = Y(0)$, $\lambda = \Lambda$ si $Y(0) > 0$ y $\lambda = c(X) = (1-\Lambda\pi_+)/(1-\pi_+)$ si $Y(0) = 0$. Entonces $\mathbb{E}_Q[\lambda \mid X] = 1$; además $c \le 1 \le \Lambda$, y $c \ge 1/\Lambda$ equivale a $\pi_+ \le 1/(1+\Lambda)$, así que MSM(Λ) se cumple. Como $\mathbb{E}_Q[\lambda \mid X] = 1$, ni la ley de X en el grupo objetivo ni los datos del canal donante cambian, y $Y(0)$ del grupo objetivo nunca se observa, así que el mundo es compatible con lo observado; en él, $\mathbb{E}_Q[\lambda Y \mid X] = \Lambda m_0(X)$ y $\theta = \Lambda\theta_0$. Para la inferior, $\lambda = 1/\Lambda$ si $Y(0) > 0$ y $\lambda = (1-\pi_+/\Lambda)/(1-\pi_+)$ si $Y(0) = 0$; este valor es ≥ 1 y es $\le \Lambda$ si $\pi_+ \le \Lambda/(1+\Lambda)$, que se cumple porque $\pi_+ \le 1/(1+\Lambda) \le \Lambda/(1+\Lambda)$.

(3) Sean $\bar\lambda_1$ y $\bar\lambda_0$ las medias de λ sobre $\{Y=1\}$ y $\{Y=0\}$ dado X. La restricción $\mathbb{E}_Q[\lambda \mid X] = 1$ es $m\bar\lambda_1 + (1-m)\bar\lambda_0 = 1$ con $\bar\lambda_0,\bar\lambda_1 \in [1/\Lambda,\Lambda]$, y $\mathbb{E}_Q[\lambda Y \mid X] = m\bar\lambda_1$. Despejando $\bar\lambda_0$, el máximo de $m\bar\lambda_1$ es $\min(\Lambda m, 1-(1-m)/\Lambda)$ y el mínimo, $\max(m/\Lambda, 1-\Lambda(1-m))$; ambos se alcanzan con λ constante en cada clase. Comprobamos además la fórmula frente a la solución por programación lineal en 2 000 casos aleatorios, con error máximo de 10^{-15}. □

Uso práctico. Con un intervalo de confianza $[\hat L,\hat U]$ para θ_0, el intervalo $[\hat L/\Lambda,\ \hat U\Lambda]$ combina la incertidumbre de muestreo con la de confusión. El Λ *de ruptura* es el menor Λ que cambia la conclusión; por ejemplo, la pérdida $\mathbb{E}[Y \mid S=1] - \theta$ sigue siendo positiva para todo $\Lambda < \mathbb{E}[Y \mid S=1]/\theta_0$.

Calibración de Λ. La comparación con covariables observadas, quitando cada una del modelo de propensión y midiendo cuánto cambian los odds, es una práctica establecida (McClean et al., 2024; Baitairian et al., 2025). Cuando el grupo objetivo es un corte en una puntuación de las propias covariables hay que hacerla con el modelo de canal, no con el de «grupo objetivo frente a donantes».

Lema 3 (Calibración con el modelo de canal)**.** *Sea $S = D \cdot \mathbf{1}\{s(X) \le c\}$ con s observada. En la región $R = \{s(X) \le c\}$,*

$$\lambda(X,U) = \frac{\text{odds}(D = 1 \mid X,U)}{\text{odds}(D = 1 \mid X)}.$$

Demostración. En la muestra combinada, por Bayes, $\text{odds}(Z = 1 \mid x,u) = \frac{\pi}{1-\pi} \cdot \frac{\mathbb{P}(S=1|x,u)/\mathbb{P}(S=1)}{\mathbb{P}(D=0|x,u)/\mathbb{P}(D=0)}$, y lo mismo sin u. En R, $\mathbb{P}(S = 1 \mid x,u) = \mathbb{P}(D = 1 \mid x,u)$ y $\mathbb{P}(S = 1 \mid x) = \mathbb{P}(D = 1 \mid x)$; las constantes se cancelan en el cociente. □

Fuera de R, el modelo del grupo objetivo está dominado por el corte, que no es confusión. Dentro de R, el lema permite calibrar con un modelo de propensión de canal ordinario. Definimos el *benchmark* de la covariable j como $\Lambda_j(q)$, el cuantil q en R de $\max(\lambda_j, 1/\lambda_j)$, con $\lambda_j = \text{odds}(D = 1 \mid X)/\text{odds}(D = 1 \mid X \text{ sin } j)$, ambos estimados fuera de muestra. Usamos cuantiles y no el máximo muestral, que crece con el tamaño de la muestra; son una escala de comparación, no una verificación del modelo. Dos advertencias: que un confusor oculto sea más débil que la covariable observada más fuerte es un supuesto, no una consecuencia de los datos; y quitar las covariables de una en una subestima la confusión si varias correlacionadas la reparten (McClean et al., 2024).

9 Diseño de la simulación

La simulación usa un generador con θ conocida y cambia un factor cada vez sobre un escenario base, de modo que cada resultado teórico tiene un escenario que lo contrasta con una predicción numérica previa.

Generador.

1. *Covariables:* $V = (V_1, \ldots, V_4)$ normal con correlaciones $0{,}3^{|j-k|}$, más V_5 categórica de 3 niveles cuya distribución depende de V_1; todas son características del cliente. Una variable U no observada, independiente de V, solo entra en el escenario de confusión no observada.
2. *Variable de canal latente:* $H = \mathbf{1}\{C^* \neq \varnothing\}$ indica historial real, con $\mathbb{P}(H = 1 \mid V) = \sigma(-0{,}4 + 0{,}8V_1 + 0{,}3V_3)$; si $H = 1$, el historial vale $N(0{,}5V_1; 1)$. Se registra si $D = 1$ y $H = 1$, y $C = \varnothing$ en otro caso.
3. *Canal:* $\mathbb{P}(D = 1 \mid V,H,U) = \sigma(\alpha_0 + \lambda\, \alpha^\top V + \zeta H + \nu U)$. El parámetro λ controla el solapamiento, y $\zeta \neq 0$ hace que la distribución de C^* dado V difiera entre canales, condición necesaria para que C^* pueda confundir.
4. *Resultados:* dos productos comunes, $\mathbb{P}(Y_k(d) = 1 \mid X^*,U) = \sigma(\beta_{k0} + \beta_{kd} + \beta_k^\top V + \delta H + \nu' U + e)$ para $k = 1,2$, con e un efecto aleatorio de cliente, y un producto exclusivo del canal premium con $Y_3(0) = 0$. El resultado que usan los estimadores es $Y = Y_1 + Y_2$.
5. *Grupo objetivo:* $S = \mathbf{1}\{D = 1, s^*(V) \le c^*\}$, con s^* el índice verdadero de propensión de compra en el canal premium y c^* su percentil 10 en ese canal. La regla es fija, así que θ no cambia entre réplicas.
6. *Unidades y observaciones:* cada cliente genera entre 1 y 5 llamadas, en número independiente de todas las demás variables, con el canal y las covariables constantes entre ellas; por eso los estimandos por unidad y por observación coinciden.

7. *Verdad:* θ y los límites teóricos de cada estimador se calculan en una población de 1,5 millones de clientes; las medias condicionales verdaderas y dP_V/dQ_V se obtienen integrando H, U y el efecto de cliente por cuadratura de Gauss–Hermite. Su error de Monte Carlo, de unos 0,001 puntos (0,015 en el escenario de confusión no observada), es despreciable frente al de las medias de las réplicas. Los efectos del recorte, mucho más pequeños, se predicen como diferencias pareadas dentro de la población.

Escenarios y predicciones. El escenario base no incluye C, tiene $\zeta \neq 0$ y $\delta = \nu = \nu' = 0$, solapamiento alto ($\lambda = 0{,}5$; $\chi^2 = 3{,}6$), LightGBM con *cross-fitting* de 5 bloques por cliente para $\hat{p}$ y $\hat{m}$, y 30 000 clientes por réplica: unas 62 000 llamadas donantes y 2 800 del grupo objetivo. Sobre él variamos la inclusión de C, la confusión por el historial ($\delta = 1{,}2$), el solapamiento ($\lambda = 1{,}5$ y 3; $\chi^2 = 6{,}3$ y 36), la especificación de los modelos, la confusión no observada ($\nu = \nu' = 1$), el recorte en los percentiles 99, 95 y 90 de los pesos donantes y el tamaño (3 000 a 30 000 clientes). Cada escenario tiene 200 réplicas, con lo que la cobertura al 95 % se estima con un error típico de unos 1,5 puntos. Las predicciones que no se derivan directamente de la teoría se registraron con fecha antes de ejecutar el escenario correspondiente; el código, las predicciones (con fecha en el historial de versiones del repositorio) y los resultados brutos se harán públicos con el artículo.

El AUC no mide el solapamiento. Al calibrar λ, el AUC del clasificador ideal se mantuvo entre 0,90 y 0,92 para λ entre 0,3 y 2, mientras χ^2 variaba entre 3,6 y unos 12, sin crecer de forma monótona (es mínima cerca de $\lambda = 0{,}5$). La propia definición del grupo objetivo, un corte en una puntuación, ya lo separa del canal donante. Por eso fijamos los niveles por χ^2, que es lo que gobierna la varianza (Proposición 6).

10 Resultados de la simulación

10.1 Identificación, variables de canal y especificación

En los ocho escenarios de la tabla 1, las medias de los estimadores convergen al límite predicho. Con muestras pequeñas fallan la dispersión y la cobertura, no la media (sección 10.5). Una discrepancia en el solapamiento medio ($z = -3{,}0$ en el Hájek y $-2{,}1$ en el DR) no reapareció en una réplica con 200 semillas nuevas ($z = +0{,}8$ y $+1{,}5$; con las 400 réplicas, $-1{,}4$ y $-0{,}3$). Esa réplica no estaba planificada de antemano; con unas 40 comparaciones, la probabilidad de algún $|z| \geq 3$ por azar ronda el 10 %.

Cuadro 1: Resultados principales. Tasas en %; entre paréntesis, z = (media − predicción)/(error de Monte Carlo). DE: desviación típica del DR entre réplicas. Cobertura del intervalo de Wald del DR al 95 %, respecto de θ. En los escenarios con C, el n_{eff}/n_0 teórico se calcula con la parte con soporte; sale prácticamente igual que sin C (0,217), porque $\mathbb{P}(H = 0 \mid V, D = 1)$ varía poco en la región objetivo.

Escenario	θ	Predicción	Hájek	DR	DE	Cobertura	n_{eff}/n_0 (teórico)
Base	0,958	0,958	0,958 (0,0)	0,961 (0,4)	0,112	95,5 %	0,14 (0,22)
Con C	0,958	H 0,940; DR 0,958	0,939 ($-0{,}1$)	0,958 (0,0)	0,107	96,5 %	0,12 (0,22)
C confunde, sin C	1,712	1,314	1,313 ($-0{,}2$)	1,320 (0,7)	0,132	15,5 %	0,14 (0,22)
C confunde, con C	1,712	H 1,281; DR 1,314	1,280 (0,0)	1,320 (0,6)	0,129	17,5 %	0,12 (0,22)
Solapamiento medio	1,178	1,178	1,151 ($-3{,}0$)	1,158 ($-2{,}1$)	0,136	94,5 %	0,10 (0,14)
Solapamiento bajo	1,274	1,274	1,283 (0,5)	1,298 (1,1)	0,300	91,0 %	0,03 (0,03)
Confusión no observada	2,697	1,193	1,198 (0,6)	1,204 (1,3)	0,127	0,0 %	0,14 (0,20)
3 000 clientes	0,958	0,958	0,887 ($-1{,}2$)	0,883 ($-1{,}2$)	0,912	70,0 %	0,02 (0,22)

- *Identificación.* Sin confusión ni variable de canal, Hájek y DR recuperan θ y el intervalo cubre el 95,5 %.
- *Variable de canal.* Con C, la masa sin soporte estimada fue $\hat{\varepsilon} = 0{,}326$, frente a $\kappa = 0{,}335$ (Proposición 3), y el Hájek converge a θ_{ac}, con el sesgo predicho de $-0{,}018$ puntos. La predicción original asignaba también al DR el límite θ_{ac} y falló ($z = 2{,}4$ y 4,3). El DR extrapola el modelo de resultado a la parte sin soporte (Corolario 2); la predicción derivada de ello (0,958 y 1,314) se añadió tras el escenario «Con C» y se registró antes de ejecutar «C confunde, con C», donde se cumplió ($z = 0{,}6$).
- *Confusión por el historial.* Sin C, el sesgo es el predicho: $-0{,}40$ puntos, un 23 % de θ. Con C tampoco se recupera θ, como dice la sección 6.
- *Confusión no observada.* Los estimadores convergen al límite predicho por los datos observables, a menos de la mitad de θ, con cobertura nula. El error típico está bien calibrado (97 % de la dispersión real) y los diagnósticos se parecen a los del escenario base: nada en los datos delata el problema.
- *Solapamiento.* Con $\chi^2 = 36$, la desviación típica casi se triplica, el error típico estimado se queda en el 87 % de la dispersión real y la cobertura baja al 91 %.

Cuadro 2: Especificación (escenario base). Tasas en %.

Clasificador	Modelo de resultado	Estimador	Predicción	Media (z)	Cobertura
LightGBM	LightGBM	DR	0,958	0,961 (0,4)	95,5 %
LightGBM	lineal en V_1	DR	0,958	0,955 ($-0{,}3$)	95,0 %
Logística lineal	LightGBM	DR	0,958	0,946 ($-2{,}3$)	88,0 %
Logística lineal	—	Hájek	1,024	1,023 ($-0{,}4$)	—
Logística lineal	lineal en V_1	DR	1,157	1,150 ($-1{,}5$)	13,5 %
—	lineal en V_1	Regresión	1,069	1,075 (1,4)	—

Con el clasificador flexible y el modelo de resultado mal especificado (lineal), el DR no tiene sesgo y cubre el 95 %; con los dos mal, converge al límite predicho, lejos de θ (tabla 2). Con el clasificador mal especificado (lineal) y el modelo de resultado flexible, queda un sesgo de $-0{,}012$ puntos y una cobertura del 88 %: el modelo de resultado es un LightGBM, no m_0, y el producto de errores no es despreciable a estos tamaños. Aun así, el DR reduce en un 82 % el sesgo del Hájek correspondiente.

10.2 Recorte

Medimos el efecto del recorte como la diferencia pareada recortado menos sin recortar dentro de cada réplica, en milésimas de punto porcentual. Con los pesos verdaderos y la respuesta verdadera m_0, en 60 réplicas del escenario base, la Proposición 5 predice $-0{,}37$, $-3{,}19$ y $-7{,}98$ en los percentiles 99, 95 y 90, y se observa $-0{,}37 \pm 0{,}02$, $-3{,}13 \pm 0{,}06$ y $-7{,}81 \pm 0{,}09$: los perfiles con más peso responden más, y el recorte baja la estimación. Con los pesos estimados por el clasificador, el signo se invierte: $+10{,}9 \pm 0{,}7$ en el percentil 90, positivo en las 60 réplicas (con las compras simuladas, el ruido lo oculta: $+6{,}8 \pm 4{,}7$). Dentro del DR, el efecto medio del recorte está entre $-0{,}1$ y $+2{,}1$ milésimas en los escenarios base y de solapamiento bajo, y entre $+6{,}4$ y $+12{,}5$ en el de solapamiento medio, sin distinguirse de cero ($|z| < 2$); en el percentil 90, la raíz del error cuadrático medio baja de 0,300 a 0,163 puntos con solapamiento bajo y de 0,111 a 0,082 en el base. Pero el error típico calculado con los pesos recortados se queda en el 64 % de la dispersión real con solapamiento bajo, y la cobertura cae al 78,5 %; con

el error típico sin recortar es del 96,5–99,5 %, conservadora en esta simulación. El mecanismo de la inversión se analiza en la nota complementaria.

10.3 Pesos con corte conocido

Comparamos el estimador con los pesos de la Proposición 2 con el estándar en las mismas réplicas: mismos datos, mismo LightGBM y mismo modelo de resultado; solo cambian los pesos. La propensión de canal se estima añadiendo las llamadas premium de fuera del grupo objetivo, que el estimador estándar no usa. Las predicciones se registraron antes de ejecutar.

Cuadro 3: Pesos con corte conocido en el escenario base, por tamaño. 200 réplicas; $\theta = 0{,}958\,\%$. DE en puntos. La última columna es el efecto del recorte del Hájek en el percentil 90 calculado con m_0, en milésimas; con los pesos verdaderos es $-7{,}8$.

Clientes	Pesos	DR (%)	DE	Cobertura	n_{eff}/n_0	Recorte p90
30 000	estándar	0,961	0,112	95,5 %	0,14	+10,4
30 000	corte conocido	0,960	0,098	92,5 %	0,20	−6,2
10 000	estándar	0,962	0,294	88,0 %	0,07	+19,8
10 000	corte conocido	0,957	0,195	91,0 %	0,17	−4,8
3 000	estándar	0,883	0,912	70,0 %	0,02	+50,0
3 000	corte conocido	0,944	0,371	87,0 %	0,11	−10,2

Se cumplen cinco de las seis predicciones (tabla 3): no hay sesgo apreciable; n_{eff}/n_0 se acerca al 0,22 teórico; la dispersión baja un 12, un 34 y un 59 %; el recorte recupera el signo de los pesos verdaderos; y la cobertura mejora con 10 000 y 3 000 clientes. Falla la cobertura con 30 000: predijimos entre el 93 y el 97 % y sale 92,5 % ± 1,9, porque el error típico se queda en el 93 % de la dispersión real. Con 10 000 clientes, la desviación típica queda un 15 % por encima de la que predice el ritmo $\sqrt{n}$ a partir del mismo estimador con 30 000 ($0{,}098 \cdot \sqrt{3} = 0{,}170$), frente al 52 % del estándar.

Un análisis posterior, no registrado de antemano, separa las dos novedades: imponer el corte y usar las unidades premium de fuera del grupo objetivo. Imponer el corte sobre el clasificador estándar, sin datos nuevos, no reduce la dispersión (0,117, 0,298 y 0,933 puntos) y corrige solo en parte el signo del recorte (+1,0, +2,7 y +9,6). La mejora viene sobre todo de estimar la propensión de canal con muchos más casos positivos; el corte conocido es lo que permite usarla.

Cuadro 4: Pesos con corte conocido en los demás escenarios (200 réplicas, mismos datos que la tabla 1). En cada celda, estándar → corte conocido. Recorte del Hájek en el percentil 90 calculado con m_0, en milésimas.

Escenario	DE del DR	Cobertura	Recorte p90
Con C	0,107 → 0,096	96,5 → 93,5 %	+16,4 → −0,4
C confunde, sin C	0,132 → 0,115	15,5 → 9,0 %	+20,1 → −7,4
C confunde, con C	0,129 → 0,113	17,5 → 6,5 %	+32,0 → +3,9
Solapamiento medio	0,136 → 0,147	94,5 → 93,5 %	+19,6 → −15,6
Solapamiento bajo	0,300 → 0,342	91,0 → 87,0 %	+34,5 → −20,6
Confusión no observada	0,127 → 0,109	0,0 → 0,0 %	+23,1 → +4,6

En los demás escenarios, con una segunda predicción registrada (tabla 4), los estimadores convergen a los mismos límites que el estándar ($|z| \leq 1{,}7$), porque solo cambia cómo se estiman los mismos pesos; con confusión, la cobertura respecto de θ es incluso menor, porque

el estimador es más preciso alrededor de un valor equivocado. Con la variable de canal no hay explosión de pesos: los donantes nunca la tienen registrada, y la falta de soporte aparece como $\hat{e} > 0{,}99$ en el 33,3 % del grupo objetivo, frente a $\kappa = 0{,}335$. Con solapamiento bajo, el recorte con estos pesos reproduce lo que la Proposición 5 predice para los pesos verdaderos ($-2{,}2$, $-12{,}1$ y $-20{,}6$ frente a $-3{,}0$, $-11{,}9$ y $-20{,}8$). El efecto del recorte se reduce mucho en todos los escenarios y pasa a ser negativo o casi nulo, salvo en «C confunde, con C» y en «Confusión no observada», donde sigue siendo positivo.

Fallan dos predicciones: la dispersión no baja con solapamiento medio, y con solapamiento bajo sube y la cobertura cae del 91 al 87 %. Nuestra interpretación, sin contrastar: al empeorar el solapamiento, la propensión de canal se acerca a 1 dentro del grupo objetivo y sus odds se estiman con pocos donantes, mientras que el clasificador estándar, con muy pocos casos positivos, los encoge hacia valores moderados. Recortar dentro del DR iguala ambos métodos: con solapamiento bajo, la raíz del error cuadrático medio en el percentil 90 es 0,160 con corte conocido y 0,163 con el estándar, con cobertura del 98 % usando el error típico sin recortar. La ventaja en precisión se limita, por tanto, a solapamientos buenos, sobre todo con muestras pequeñas.

10.4 Sensibilidad

El Λ mínimo cuyo intervalo puntual contiene θ es θ/θ_0: 1,30 cuando el historial confunde y 2,26 con confusión no observada. La cobertura del intervalo combinado $[\hat{L}/\Lambda, \hat{U}\Lambda]$ sube deprisa alrededor de ese valor (tabla 5); queda por debajo de la aproximación normal porque el error típico es menor en las réplicas con estimación baja (correlación de 0,64 y 0,70). La condición de resultado raro de la Proposición 7, comprobada mediante la cota $\mathbb{P}(Y > 0 \mid V, D = 0) \leq g(V) = \mathbb{E}[Y \mid V, D = 0]$ en el percentil 99,99 de g en el canal donante (no en el supremo esencial), vale al menos hasta $\Lambda = 5{,}6$ en el escenario base, 1,8 en el de confusión por el historial y 7,3 en el de confusión no observada. Con U normal, λ no está acotado y ningún Λ finito cumple el modelo MSM en sentido estricto, así que en ese escenario la Proposición 7 no garantiza nada; $\Lambda = 2{,}26$ contiene θ por construcción, y lo usamos solo como escala.

Cuadro 5: Cobertura del intervalo combinado de sensibilidad.

Escenario	θ/θ_0	$\Lambda = 1{,}25$	$\Lambda = 1{,}5$	$\Lambda = 2$	$\Lambda = 2{,}5$
C confunde, sin C	1,30	87 %	100 %	100 %	100 %
Confusión no observada	2,26	0 %	3 %	71 %	99 %

Para calibrar Λ, en el escenario de confusión no observada U entra en el canal con coeficiente 1 y la covariable observada más fuerte, V_1, con 0,5. Predijimos, antes de calcularlo, que el método del Lema 3 recuperaría el valor exacto para U y que U superaría a todas las covariables observadas; ambas se cumplen (tabla 6). El Λ necesario para cubrir la verdad, 2,26 (conocido aquí solo porque conocemos θ), queda entre la mediana y el cuantil 90 de V_1: basta un confusor algo más fuerte que la covariable observada más fuerte para explicar toda la diferencia. No es el Λ de ruptura de la sección 8, que depende de la conclusión de interés y se calcula con los datos. En una segunda estimación con otra muestra, el modelo «grupo objetivo frente a donantes» coincide con el de canal en la mediana (2,06 frente a 1,99), pero sobrestima los extremos: 6,34 y 29,98 en los cuantiles 90 y 99, frente a 5,37 y 15,51 con el de canal y 5,38 y 14,07 exactos.

Cuadro 6: Calibración de Λ con el modelo de canal: cuantiles en R de $\max(\lambda, 1/\lambda)$.

Variable	Mediana	Cuantil 90	Cuantil 99
U, exacto	1,99	5,38	14,07
U, estimado	2,03	5,21	14,14
V_1	1,72	3,07	5,81
V_2	1,17	1,53	2,17
V_3	1,14	1,45	1,98
V_4	1,12	1,36	1,70
V_5	1,08	1,21	1,42

10.5 Tamaño muestral e intervalos: Wald y bootstrap

Con el estimador estándar, la desviación típica del DR es 0,912, 0,508, 0,294, 0,183 y 0,112 puntos con 3 000, 5 000, 10 000, 15 000 y 30 000 clientes: cae como $n^{-0,91}$, mucho más deprisa que $n^{-1/2}$, y la cobertura del intervalo de Wald es del 70, 80, 88, 92 y 95,5 %. Las predicciones de 5 000 y 15 000 se registraron de antemano y se cumplieron. El cociente n_{eff}/n_0 estimado sigue la misma progresión (0,02, 0,07 y 0,14 con 3 000, 10 000 y 30 000, frente al 0,22 teórico). Esto sugiere un diagnóstico, aún sin contrastar: si n_{eff}/n_0 sigue creciendo al aumentar la muestra, los intervalos todavía no son fiables.

Cuadro 7: Bootstrap por cliente: error típico medio en puntos y, entre paréntesis, cobertura al 95 %, en las mismas 40 réplicas.

Clientes	DE real	Wald	Bootstrap con reemplazo	Bootstrap bayesiano
30 000	0,109	0,102 (98 %)	0,162 (100 %)	0,147 (100 %)
10 000	0,274	0,230 (82 %)	0,432 (100 %)	0,370 (98 %)

Evaluamos el bootstrap por cliente con reemplazo, reestimando LightGBM y el *cross-fitting* en cada uno de 60 remuestreos, en 80 réplicas con 30 000 y 10 000 clientes, y, en 40 de ellas, una variante bayesiana que da a cada cliente un peso $\text{Exp}(1)$ en lugar de copias. Las cuatro predicciones registradas fallaron (tabla 7). Predijimos que el bootstrap con reemplazo quedaría cerca de la dispersión real con 30 000 clientes y entre Wald y la dispersión real con 10 000; los dos la sobrestiman (en las 80 réplicas, 0,165 frente a 0,119 y 0,446 frente a 0,322). Atribuimos el exceso a las copias de clientes y predijimos que la variante bayesiana lo eliminaría, pero solo reduce el error típico un 9 y un 14 %, y el exceso sobre la dispersión real un 28 y un 39 %.

Una segunda comprobación, también registrada, apunta a la causa. Aplicado al estimador con pesos de corte conocido, cuyos pesos son mucho menos ruidosos, el bootstrap bayesiano queda casi calibrado: error típico medio de 0,101 frente a una dispersión real de 0,096 en las mismas 40 réplicas con 30 000 clientes, y de 0,208 frente a 0,187 con 10 000, con coberturas del 95 y del 90 % (± 5). Esto indica que el exceso está ligado al ruido de los pesos estimados: remuestrear reduce la información efectiva, y como con el clasificador estándar la dispersión crece mucho al reducirla, el mundo bootstrap la exagera. Es evidencia de un solo generador de datos, no una demostración.

11 Discusión

Recomendaciones prácticas. De la teoría y de la simulación se siguen seis pautas para evaluar un cambio de canal con datos observacionales:

1. Si el grupo objetivo es un corte en una puntuación conocida, estimar los pesos con la propensión de canal, usando todas las unidades del canal premium, e imponer el corte (Proposición 2).
2. Excluir de las covariables las variables que solo registra un canal cuando no predicen el resultado dadas las demás (Proposición 4), y diagnosticar la falta de soporte con la masa de $\hat{p}$ o $\hat{e}$ cercana a 1 (Proposición 3). Cuando la medición distinta conserva el soporte, ninguna comprobación con los datos la detecta (Teorema 4); hace falta información externa.
3. Usar el estimador doblemente robusto con *cross-fitting* por unidad, sabiendo que sin soporte extrapola el modelo de resultado (Corolario 2).
4. Para el intervalo, Wald con muestras grandes. Con muestras medianas y pesos de corte conocido, tanto Wald como el bootstrap bayesiano por unidad quedaron cerca del nivel nominal en la simulación (90–95 %, el bootstrap con solo 40 réplicas); con el clasificador estándar, el bootstrap es conservador. Desconfiar si n_{eff}/n_0 sale muy por debajo de lo esperable.
5. No trasladar el signo del recorte de los pesos verdaderos a los estimados sin comprobarlo. Si se recorta, hacerlo dentro del estimador doblemente robusto y calcular el error típico con los pesos sin recortar.
6. Acompañar la estimación de un análisis de sensibilidad con Λ calibrado frente a las covariables observadas mediante el modelo de canal (Lema 3).

Limitaciones. Toda la evidencia empírica procede de un único generador de datos, construido para que cada resultado teórico tuviera un escenario que lo contrastase; las conclusiones cuantitativas de la simulación, como las ganancias del corte conocido o el exceso del bootstrap, deben leerse como ilustraciones de los mecanismos, no como magnitudes generales. Las cotas de sensibilidad suponen el modelo MSM, que con confusores no acotados no se cumple en sentido estricto. Tratamos el umbral que define el grupo objetivo como fijo. Y el estimando es la media contrafactual con el canal básico tal como es hoy: si recibir las unidades desviadas lo satura, (A1) falla.

Problemas abiertos. Cuatro preguntas quedan sin respuesta: una teoría que explique el exceso del bootstrap con pesos estimados ruidosos y la validez del bootstrap bayesiano con los pesos de corte conocido; la contribución a la varianza de un umbral estimado como cuantil de la puntuación, que se relaciona con la elección del propio umbral; la combinación del análisis de sensibilidad con la falta de soporte (Corolario 1; Ma y Namkoong, 2025) y su extensión a la condición (3) de la Proposición 4; y una ilustración con datos públicos en la que las covariables se midan de forma distinta en los dos grupos.

A Prueba del Teorema 5

El estimador doblemente robusto es θ más una media de términos i.i.d. de media cero, más restos de orden $o_P(n^{-1/2})$; el teorema central del límite hace el resto.

Notación. Trabajamos primero con observaciones i.i.d. $O = (Z,X,Y)$; el caso con varias observaciones por unidad se trata al final. $P_n f = n^{-1}\sum_i f(O_i)$; $\mathbb{E}f$ es la esperanza poblacional; $\|h\|_Q$ y $\|h\|_P$ son normas de $L^2(Q)$ y $L^2(P)$. Sean $\bar{o} = (1-\eta)/\eta$ y $\bar{w} = (1-\pi)\bar{o}/\pi$: por la

condición 1 y el Teorema 2, $o \le \bar{o}$ y $w \le \bar{w}$, y por la condición 2, $\hat{o} \le \bar{o}$. Las observaciones están acotadas: $|Y| \le M$ y $|\hat{m}| \le M$. En el bloque k, con n_k observaciones, $(\hat{o}_k,\hat{m}_k)$ se entrenan con los datos de fuera del bloque; $\mathbb{E}_k$ y $\mathbb{P}_k$ denotan esperanza y probabilidad condicionadas a esos datos, y $P_{n,k}$ la media empírica dentro del bloque.

Tres identidades. Para toda h medible y acotada:

$$\begin{aligned}
&\text{(I1)} \quad \mathbb{E}[(1-Z)\,o(X)\,h(X)] = \pi\,\mathbb{E}_P[h],\\
&\text{(I2)} \quad \mathbb{E}[(1-Z)\,h(X)\,(Y-m_0(X))] = 0,\\
&\text{(I3)} \quad \|h\|_P^2 \le \bar{w}\,\|h\|_Q^2.
\end{aligned}$$

(I1): $\mathbb{E}[(1-Z)oh] = (1-\pi)\mathbb{E}_Q[oh]$, y $o = \pi w/(1-\pi)$ por el Teorema 2, luego vale $\pi\mathbb{E}_Q[wh] = \pi\mathbb{E}_P[h]$. (I2): torre condicionando en X sobre $\{Z = 0\}$, donde $\mathbb{E}[Y \mid X,Z=0] = m_0(X)$. (I3): $\|h\|_P^2 = \mathbb{E}_Q[wh^2] \le \bar{w}\,\mathbb{E}_Q[h^2]$.

Paso 1 (la función ψ y su sesgo). Para funciones acotadas (o',m'), sea $\psi(O;o',m') = (1-Z)\,o'(X)\,(Y-m'(X)) + Z\,(m'(X)-\theta)$. Entonces $\pi\phi = \psi(\cdot;o,m_0)$ y

$$\mathbb{E}[\psi(O;o',m')] = (1-\pi)\,\mathbb{E}_Q[(o'-o)(m_0-m')].$$

Por (I2) con $h = o'$, $\mathbb{E}[(1-Z)o'(Y-m')] = (1-\pi)\mathbb{E}_Q[o'(m_0-m')]$. Por (A2), $\theta = \mathbb{E}_P[m_0]$, y por (I1) con $h = m'-m_0$, $\mathbb{E}[Z(m'-\theta)] = \pi\mathbb{E}_P[m'-m_0] = (1-\pi)\mathbb{E}_Q[o(m'-m_0)]$. Sumando se obtiene la fórmula; en particular, $\mathbb{E}\phi = 0$. Es la Proposición 1 escrita con odds.

Paso 2 (linealización). Con $\hat{A} = P_n[(1-Z)\hat{o}(Y-\hat{m})]$, $\hat{B} = P_n[(1-Z)\hat{o}]$ y $\hat{\pi} = P_nZ$, el estimador es $\hat{\theta} = \hat{A}/\hat{B} + P_n[Z\hat{m}]/\hat{\pi}$. Como $P_n[Z\theta]/\hat{\pi} = \theta$, el álgebra da exactamente

$$\hat{\theta}-\theta = \frac{1}{\pi}P_n\psi(O;\hat{o},\hat{m}) + \hat{A}\Big(\frac{1}{\hat{B}}-\frac{1}{\pi}\Big) + P_n[Z(\hat{m}-\theta)]\Big(\frac{1}{\hat{\pi}}-\frac{1}{\pi}\Big).$$

Los pasos 3 y 4 muestran que el primer término es $P_n\phi + o_P(n^{-1/2})$; el paso 5, que los otros dos son $o_P(n^{-1/2})$.

Paso 3 (proceso empírico). Sea $\Delta_k = \psi(\cdot;\hat{o}_k,\hat{m}_k) - \psi(\cdot;o,m_0)$. Condicionado a los datos de fuera del bloque k, $\hat{o}_k$ y $\hat{m}_k$ son funciones fijas y los $\Delta_k(O_i)$ del bloque son i.i.d. Por la desigualdad de Chebyshev condicional, para todo $\epsilon > 0$,

$$\mathbb{P}_k\Big(\big|(P_{n,k}-\mathbb{E}_k)\Delta_k\big| > \epsilon\,n^{-1/2}\Big) \le \frac{n}{n_k}\,\frac{\mathbb{E}_k[\Delta_k^2]}{\epsilon^2}.$$

Como $\Delta = (1-Z)[(\hat{o}-o)(Y-m_0) + \hat{o}(m_0-\hat{m})] + Z(\hat{m}-m_0)$ y $|Y-m_0| \le 2M$, la desigualdad $(a+b+c)^2 \le 3(a^2+b^2+c^2)$ y (I3) dan

$$\mathbb{E}_k[\Delta_k^2] \le 3\Big[4M^2(1-\pi)\,\|\hat{o}_k-o\|_Q^2 + \big((1-\pi)\bar{o}^{\,2} + \pi\bar{w}\big)\,\|\hat{m}_k-m_0\|_Q^2\Big],$$

que tiende a 0 en probabilidad por la condición 3. Como $n/n_k \to K$, la probabilidad condicional tiende a 0 en probabilidad, y al estar acotada por 1, la convergencia dominada da que la probabilidad sin condicionar también tiende a 0. Luego $(P_{n,k}-\mathbb{E}_k)\Delta_k = o_P(n^{-1/2})$ para cada uno de los K bloques.

Paso 4 (sesgo). Como $\mathbb{E}_k\psi(\cdot;o,m_0)=0$, el paso 1 y Cauchy–Schwarz dan

$$|\mathbb{E}_k\Delta_k| = (1-\pi)\big|\mathbb{E}_Q[(\hat{o}_k-o)(m_0-\hat{m}_k)]\big| \le (1-\pi)\, r_o\, r_m = o_P(n^{-1/2}).$$

Sumando sobre los bloques con pesos n_k/n, $P_n\psi(\cdot;\hat{o},\hat{m}) = P_n\psi(\cdot;o,m_0) + o_P(n^{-1/2}) = \pi P_n\phi + o_P(n^{-1/2})$.

Paso 5 (normalizaciones). Descomponemos los factores del paso 2 en una parte i.i.d. y una de error de los parámetros auxiliares:

- $\hat{A} = P_n[(1-Z)o(Y-m_0)] + P_n[(1-Z)\{(\hat{o}-o)(Y-m_0)+\hat{o}(m_0-\hat{m})\}]$. El primer sumando es $O_P(n^{-1/2})$ por el teorema central del límite. En el segundo, la parte centrada es $o_P(n^{-1/2})$ con el argumento del paso 3, y su media condicional, por (I2), es $(1-\pi)\mathbb{E}_Q[\hat{o}_k(m_0-\hat{m}_k)]$, acotada por $(1-\pi)\bar{o}\, r_m$. Luego $\hat{A} = O_P(n^{-1/2}) + O_P(r_m)$.
- Del mismo modo, $\hat{B}-\pi = (P_n-\mathbb{E})[(1-Z)o] + P_n[(1-Z)(\hat{o}-o)] = O_P(n^{-1/2}) + O_P(r_o)$, usando $\mathbb{E}[(1-Z)o]=\pi$ por (I1) y que la norma de $L^1(Q)$ no supera a la de $L^2(Q)$.
- $P_n[Z(\hat{m}-\theta)] = P_n[Z(m_0-\theta)] + P_n[Z(\hat{m}-m_0)] = O_P(n^{-1/2}) + O_P(r_m)$, usando $\mathbb{E}[Z(m_0-\theta)]=0$ y (I3). Además, $1/\hat{\pi}-1/\pi = O_P(n^{-1/2})$.

Como $\hat{B}\to\pi>0$ en probabilidad,

$$\hat{A}\Big(\frac{1}{\hat{B}}-\frac{1}{\pi}\Big) = \frac{\hat{A}(\pi-\hat{B})}{\pi\hat{B}} = O_P\big(n^{-1}+n^{-1/2}(r_o+r_m)+r_o r_m\big) = o_P(n^{-1/2}),$$

y el tercer término del paso 2 es $O_P(n^{-1/2})\cdot[O_P(n^{-1/2})+O_P(r_m)] = o_P(n^{-1/2})$.

Paso 6 (conclusión). $\hat{\theta}-\theta = P_n\phi + o_P(n^{-1/2})$. Las $\phi(O_i)$ son i.i.d., con $\mathbb{E}\phi=0$ y $\mathbb{E}\phi^2 = V<\infty$, porque ϕ está acotada. El teorema central del límite y el lema de Slutsky dan $\sqrt{n}(\hat{\theta}-\theta)\to N(0,V)$.

Paso 7 (estimación de V). El estimador implementado usa

$$\hat{\phi}(O) = \frac{(1-Z)\,\hat{o}(X)\,\big(Y-\hat{m}(X)-\hat{A}/\hat{B}\big)}{\hat{B}} + \frac{Z\,(\hat{m}(X)-\hat{C})}{\hat{\pi}}, \qquad \hat{C} = \frac{P_n[Z\hat{m}]}{\hat{\pi}}.$$

Todas las funciones están acotadas, así que $|\hat{\phi}-\phi| \le c\,(|\hat{o}-o| + |\hat{m}-m_0| + |\hat{C}-\theta| + |\hat{A}/\hat{B}| + |\hat{B}-\pi| + |\hat{\pi}-\pi|)$ para una constante c. Las medias condicionales de los cuadrados de los dos primeros términos tienden a 0 por bloques, y los escalares tienden a 0 en probabilidad, así que $P_n(\hat{\phi}-\phi)^2 = o_P(1)$. Con $P_n\phi^2\to V$ por la ley de los grandes números y Cauchy–Schwarz, $|P_n\hat{\phi}^2 - P_n\phi^2| \le P_n(\hat{\phi}-\phi)^2 + 2[P_n(\hat{\phi}-\phi)^2\cdot P_n\phi^2]^{1/2}\to 0$. Así $\hat{V}\to V$ en probabilidad, y por Slutsky el intervalo $\hat{\theta}\pm z_{1-\alpha/2}(\hat{V}/n)^{1/2}$ tiene cobertura asintótica $1-\alpha$.

Varias observaciones por unidad. Si cada unidad i aporta un bloque de $m_i \le \bar{m}$ observaciones con el mismo Z_i, las unidades son i.i.d. y P y Q se definen como leyes a nivel de observación, todo lo anterior se repite con cantidades de bloque. Las identidades (I1)–(I3) valen para sumas de bloque por linealidad, con π sustituido por $\bar{N}_1 = \mathbb{E}[\sum_j Z_{ij}]$, el número esperado de observaciones objetivo por unidad, y o por los odds a nivel de observación. El *cross-fitting* por unidad mantiene la independencia entre el bloque evaluado y los datos de entrenamiento, y $m_i\le\bar{m}$ mantiene todo acotado. La función de influencia por unidad es $\sum_j \psi(O_{ij};o,m_0)/\bar{N}_1$, y $\sqrt{n}$ se refiere al número de unidades; el error típico agrupado es su versión muestral.

Referencias

Baitairian, J.-B., Sebastien, B., Jreich, R., Katsahian, S. y Guilloux, A. (2025). Calibrating confounding strength in sensitivity models for weighting estimators: a comparative review and a new method. arXiv:2510.16560.

Bickel, S., Brückner, M. y Scheffer, T. (2009). Discriminative learning under covariate shift. *Journal of Machine Learning Research*, 10, 2137–2155.

Blake, H. A., Leyrat, C., Mansfield, K. E., Seaman, S., Tomlinson, L. A., Carpenter, J. y Williamson, E. J. (2020). Propensity scores using missingness pattern information: a practical guide. *Statistics in Medicine*, 39, 1641–1657.

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W. y Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.

Cook, T. D., Shadish, W. R. y Wong, V. C. (2008). Three conditions under which experiments and observational studies produce comparable causal estimates. *Journal of Policy Analysis and Management*, 27(4), 724–750.

Crump, R. K., Hotz, V. J., Imbens, G. W. y Mitnik, O. A. (2009). Dealing with limited overlap in estimation of average treatment effects. *Biometrika*, 96(1), 187–199.

D'Agostino, R. B., Jr. y Rubin, D. B. (2000). Estimating and using propensity scores with partially missing data. *Journal of the American Statistical Association*, 95, 749–759.

Dahabreh, I. J., Robertson, S. E., Tchetgen Tchetgen, E. J., Stuart, E. A. and Hernán, M. A. (2019). Generalizing causal inferences from individuals in randomized trials to all trial-eligible individuals. *Biometrics*, 75(2), 685–694.

D'Amour, A., Ding, P., Feller, A., Lei, L. y Sekhon, J. (2021). Overlap in observational studies with high-dimensional covariates. *Journal of Econometrics*, 221, 644–654.

de Luna, X., Waernbaum, I. y Richardson, T. S. (2011). Covariate selection for the nonparametric estimation of an average treatment effect. *Biometrika*, 98(4), 861–875.

Dong, J., Zhang, J. L., Zeng, S. y Li, F. (2020). Subgroup balancing propensity score. *Statistical Methods in Medical Research*, 29(3), 659–676.

Dorn, J. y Guo, K. (2023). Sharp sensitivity analysis for inverse propensity weighting via quantile balancing. *Journal of the American Statistical Association*, 118(544), 2645–2657.

Hahn, J. (1998). On the role of the propensity score in efficient semiparametric estimation of average treatment effects. *Econometrica*, 66(2), 315–332.

Heckman, J. J., Ichimura, H. y Todd, P. E. (1997). Matching as an econometric evaluation estimator: evidence from evaluating a job training programme. *The Review of Economic Studies*, 64(4), 605–654.

Hirano, K., Imbens, G. W. y Ridder, G. (2003). Efficient estimation of average treatment effects using the estimated propensity score. *Econometrica*, 71(4), 1161–1189.

Imai, K. and Yamamoto, T. (2010). Causal inference with differential measurement error: nonparametric identification and sensitivity analysis. *American Journal of Political Science*, 54(2), 543–560.

Khan, S. y Tamer, E. (2010). Irregular identification, support conditions, and inverse weight estimation. *Econometrica*, 78(6), 2021–2042.

Liu, Y., Li, H., Zhou, Y. y Matsouaka, R. A. (2023). Average treatment effect on the treated, under lack of positivity. arXiv:2309.01334.

Ma, X. y Wang, J. (2020). Robust inference using inverse probability weighting. *Journal of the American Statistical Association*, 115, 1851–1860.

Ma, Y. y Namkoong, H. (2025). A sensitivity approach to causal inference under limited overlap. arXiv:2511.22003.

Ma, Y., Sant'Anna, P. H. C., Sasaki, Y. y Ura, T. (2023). Doubly robust estimators with weak overlap. arXiv:2304.08974.

McClean, A., Branson, Z. y Kennedy, E. H. (2024). Calibrated sensitivity models. arXiv:2405.08738.

Petersen, M. L., Porter, K. E., Gruber, S., Wang, Y. y van der Laan, M. J. (2012). Diagnosing and responding to violations in the positivity assumption. *Statistical Methods in Medical Research*, 21(1), 31–54.

Qin, J. (1998). Inferences for case-control and semiparametric two-sample density ratio models. *Biometrika*, 85(3), 619–630.

Rassen, J. A., Glynn, R. J., Rothman, K., Setoguchi, S. y Schneeweiss, S. (2012). Applying propensity scores estimated in a full cohort to adjust for confounding in subgroup analyses. *Pharmacoepidemiology and Drug Safety*, 21(7), 697–709.

Rudin, W. (1987). *Real and Complex Analysis* (3.ª ed.). McGraw-Hill.

Steiner, P. M., Cook, T. D. y Shadish, W. R. (2011). On the importance of reliable covariate measurement in selection bias adjustments using propensity scores. *Journal of Educational and Behavioral Statistics*, 36(2), 213–236.

Sugiyama, M., Suzuki, T. y Kanamori, T. (2012). *Density Ratio Estimation in Machine Learning*. Cambridge University Press.

Tan, Z. (2006). A distributional approach for causal inference using propensity scores. *Journal of the American Statistical Association*, 101(476), 1619–1634.

VanderWeele, T. J. y Shpitser, I. (2011). A new criterion for confounder selection. *Biometrics*, 67(4), 1406–1413.

Westreich, D., Cole, S. R., Funk, M. J., Brookhart, M. A. y Stürmer, T. (2011). The role of the c-statistic in variable selection for propensity score models. *Pharmacoepidemiology and Drug Safety*, 20(3), 317–320.

Westreich, D., Edwards, J. K., Lesko, C. R., Stuart, E. and Cole, S. R. (2017). Transportability of trial results using inverse odds of sampling weights. *American Journal of Epidemiology*, 186(8), 1010–1014.

Zhao, Q., Small, D. S. and Bhattacharya, B. B. (2019). Sensitivity analysis for inverse probability weighting estimators via the percentile bootstrap. *Journal of the Royal Statistical Society: Series B*, 81(4), 735–761.